Quelques statistiques sur le corpus

Extrait de EmoVid

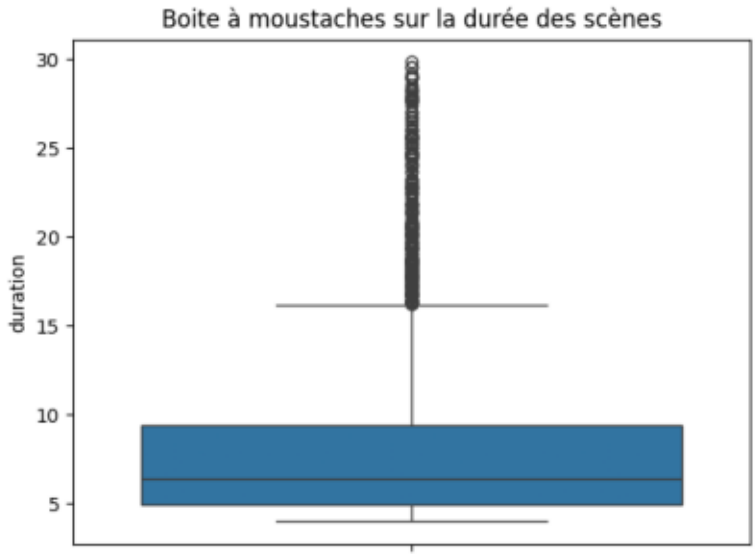
Brève description du corpus

- 350 films
- 3088 scènes
- 8 émotions

	video_id	brightness	colorfulness	hue	emotion	caption	duration	film_id
0	00000_clip_001	0.4	0.3	79	anger	The video shows a man with red hair wearing a ...	5.00	00000
1	00000_clip_002	0.5	0.3	30	anger	In the video, a man in a blue shirt and black ...	6.21	00000
2	00000_clip_006	0.5	0.2	95	contentment	The video shows two men standing on a tennis c...	7.38	00000
3	00000_clip_009	0.4	0.3	49	anger	In the video, two men are standing in front of...	4.80	00000
4	00000_clip_012	0.4	0.3	65	anger	In the video, a man in a blue shirt and a man ...	5.25	00000

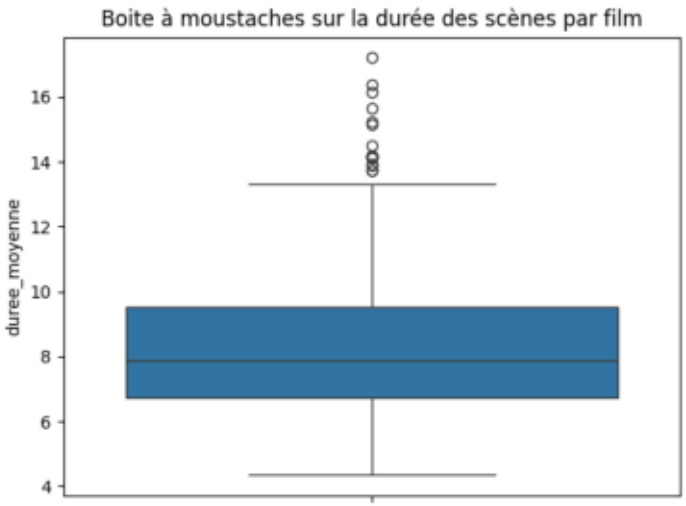
Quelques chiffres sur la durée des extraits

count	3088.000000
mean	8.141580
std	4.737166
min	4.000000
25%	4.960000
50%	6.420000
75%	9.432500
max	29.820000

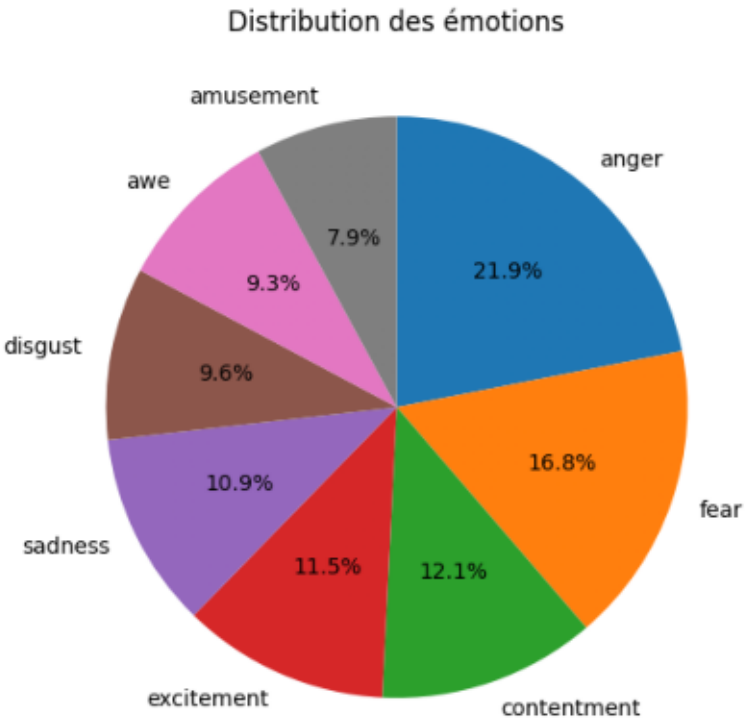


… sur les extraits par film

	duree_moyenne	nb_extraits
count	350.000000	350.000000
mean	8.350200	8.822857
std	2.379267	3.428775
min	4.340000	2.000000
25%	6.740000	6.000000
50%	7.885000	8.000000
75%	9.520000	11.000000
max	17.200000	22.000000



Distribution des émotions



On voudrait que ces proportions soient respectées lors de la séparation du corpus en train, dev et test.

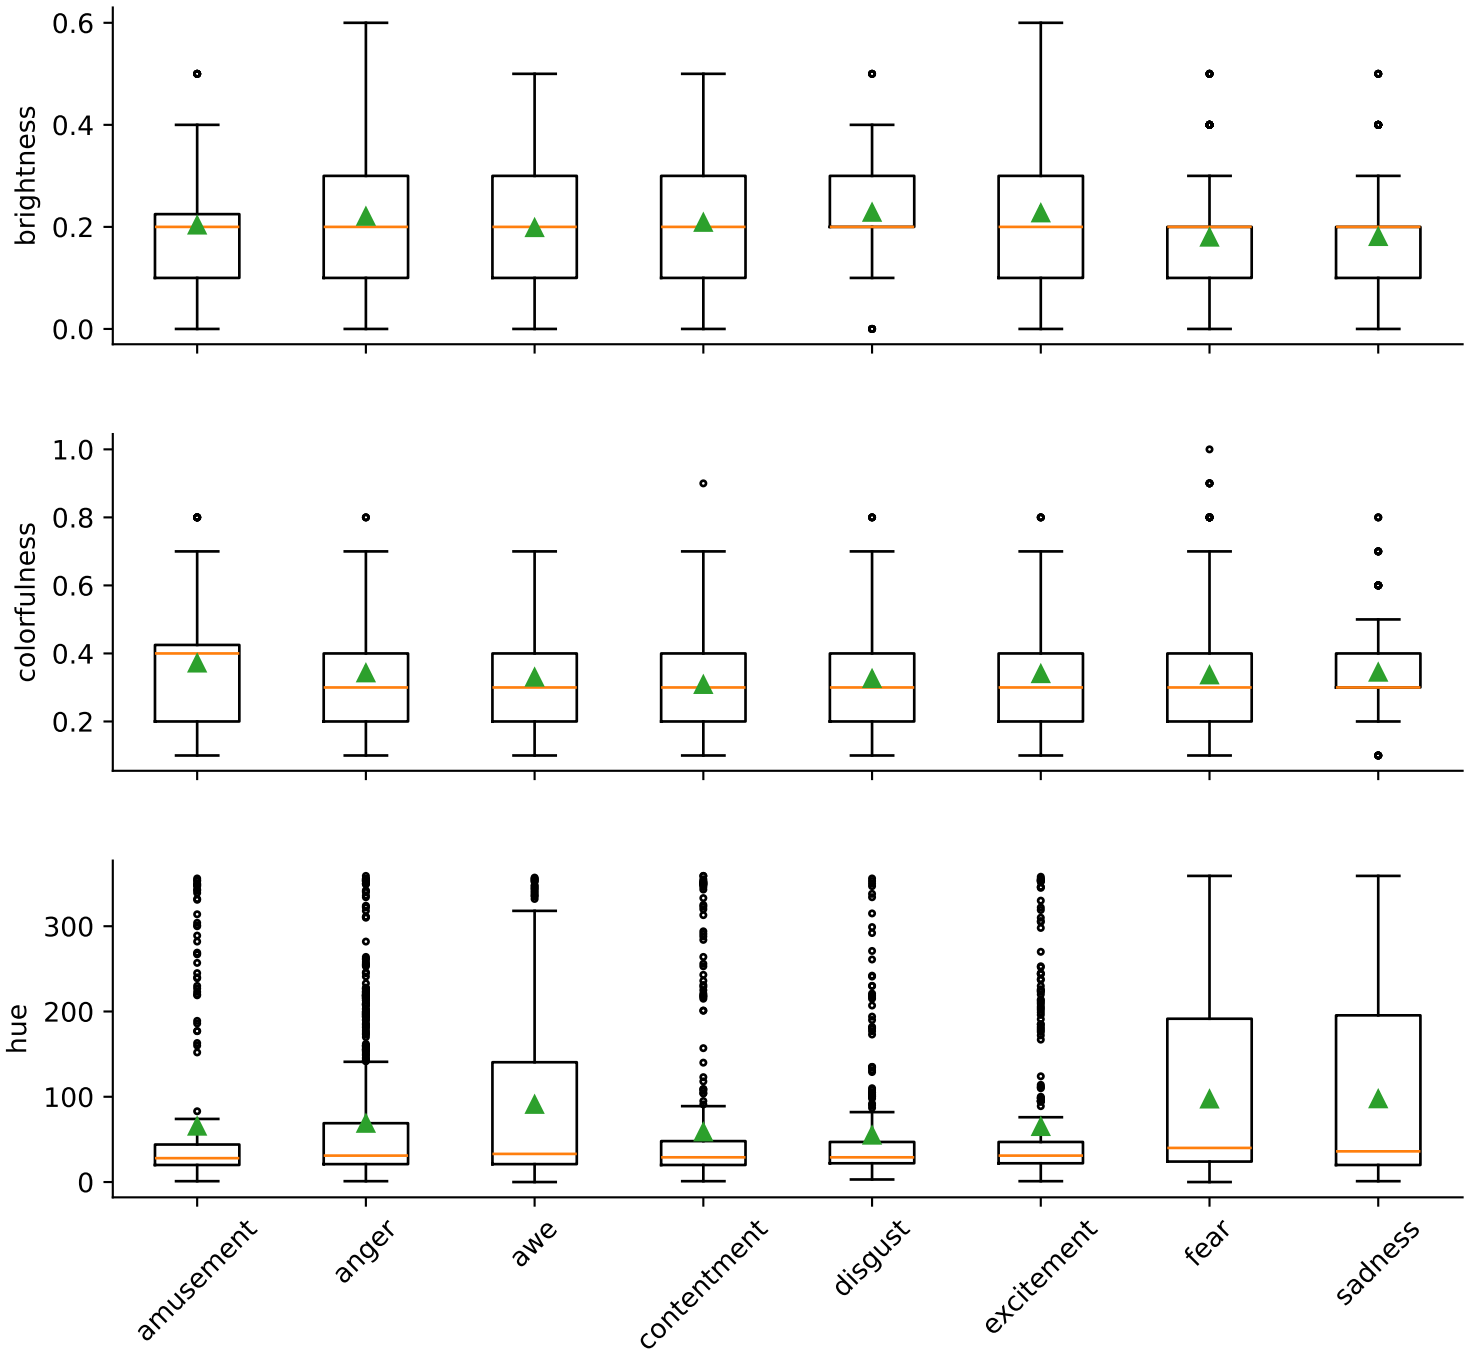
Quels films dominent chaque émotion ?

	film_1	part_1	film_2	part_2	film_3	part_3	part_top3
amusement	00111	0.049	00365	0.045	00228	0.037	0.131
anger	00000	0.016	00002	0.015	00369	0.015	0.046
awe	00286	0.038	00097	0.031	00181	0.031	0.101
contentment	00327	0.027	00108	0.024	00057	0.021	0.072
disgust	00028	0.037	00129	0.027	00216	0.024	0.088
excitement	00062	0.025	00093	0.025	00166	0.025	0.076
fear	00287	0.021	00177	0.019	00245	0.017	0.058
sadness	00142	0.038	00130	0.036	00060	0.033	0.107

- 13,1 % de l’amusement présent dans ce corpus vient des films 00111, 00365 et 00228
- 10,7% de la tristesse vient des films 00142, 00130 et 00060

ANOVA : variables visuelles selon l'émotion

H0 : la moyenne de la variable est la même pour les 8 émotions



Variable	F	p-value
brightness	13.07	1.1e-16
colorfulness	4.85	1.9e-05
hue	13.78	1.1e-17

Les trois variables diffèrent significativement selon l'émotion.

- Les émotions fear et sadness sont associées à des scènes plus sombres.
- Les émotions amusement et excitement sont associées aux scènes les plus colorées, contentment aux moins colorées.
- Les émotions fear, sadness et awe sont associées à des teintes plus élevées.

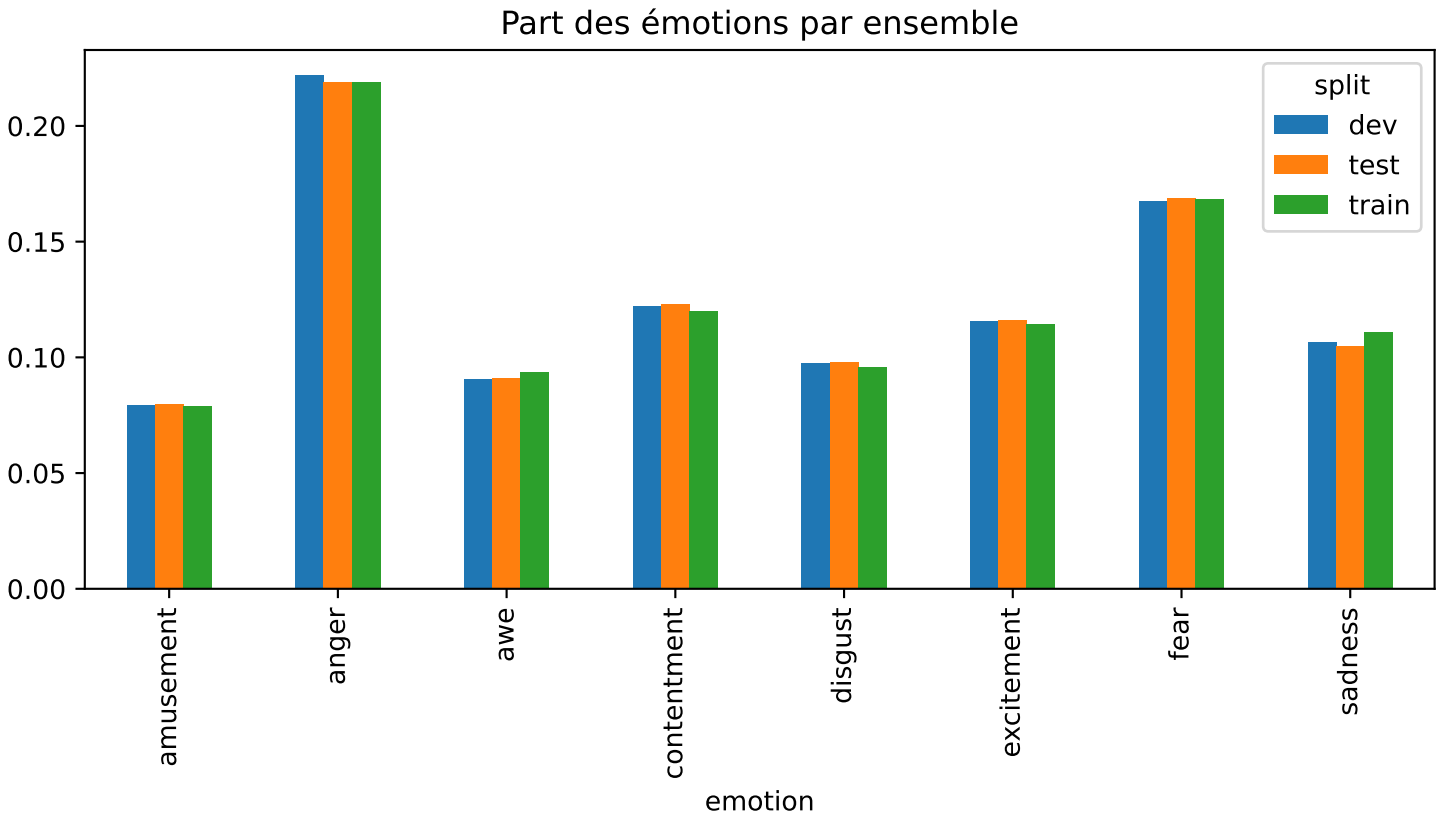
Répartition des films : train / dev / test

Méthode : StratifiedGroupKFold (7 groupes, random_state = 1).

- 7 groupes car 350 films / 50 films = 7 : chaque groupe contient environ 50 films.
- groupé par film : tous les clips d'un film restent dans le même ensemble, ce qui évite qu'un même film apparaisse à la fois en train et en test ;
- stratifié sur l'émotion : chaque groupe garde la distribution des émotions de départ.

Deux groupes de 50 films servent de test et de dev, les 5 autres forment le train (250 films).

Ensemble	Films	Clips
train	250	2207
dev	50	442
test	50	439



	total	train	dev	test
anger	21.9 %	21.9 %	22.2 %	21.9 %
fear	16.8 %	16.8 %	16.7 %	16.9 %
contentment	12.1 %	12.0 %	12.2 %	12.3 %
excitement	11.5 %	11.4 %	11.5 %	11.6 %
sadness	10.9 %	11.1 %	10.6 %	10.5 %
disgust	9.6 %	9.6 %	9.7 %	9.8 %
awe	9.3 %	9.3 %	9.0 %	9.1 %
amusement	7.9 %	7.9 %	7.9 %	8.0 %

Les proportions sont quasi identiques dans les trois ensembles.