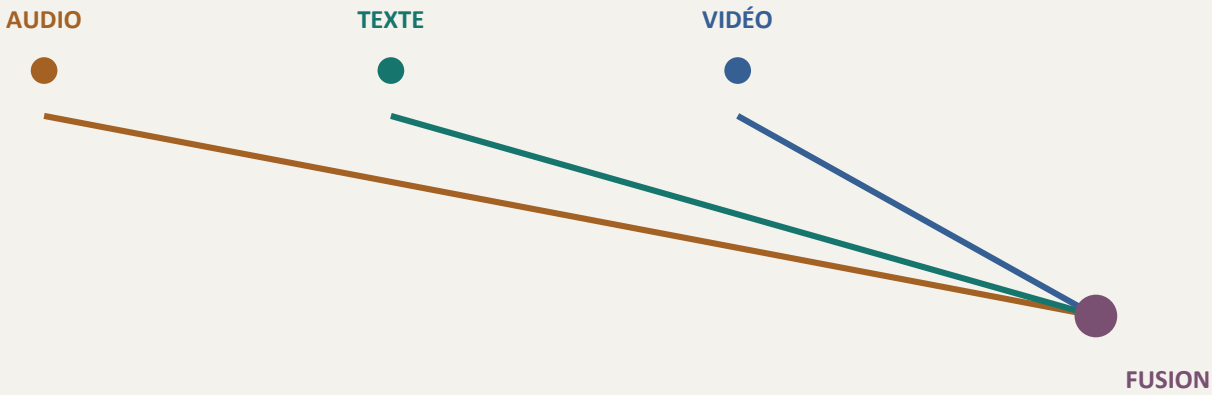
PROJET DONNÉES MULTIMÉDIA - M2 SID 2026-2027

EmoVid

Reconnaissance d'émotions dans des extraits de film

Texte, audio, vidéo et fusion des modalités



DÉPÔT DU PROJET

https://gitlab.com/Maouloud3-0/projet-multimedia-m2sid

Groupe 4

Gaoussou Maouloud KONTA

Hanchen LI

M2 SID — Université Toulouse III

Projet Données multimédia, novembre 2026

Lire le rapport

Une démarche commune, trois modalités, une décision finale.

Résumé 5

1. Introduction 5

2. Données et partition (point 2) 6

3. Transcription des dialogues (point 3) 9

4. Protocole commun des modèles 13

5. Modèle audio (point 4) 17

6. Modèle texte (point 4) 27

7. Modèle vidéo (point 4) 33

8. Fusion des modalités (point 5) 39

9. Analyse des erreurs 47

10. Conclusion, limites et pistes 48

Annexe A. Les descripteurs du N1 audio 49

Annexe B. Les 76 configurations du N2 audio 50

Annexe C. Réglages retenus 50

Annexe D. Organisation du dépôt et reproduction 51

Annexe E. Glossaire 52

Annexe F. Les têtes d'attention couche par couche 52

REPÈRES DE LECTURE

Les encadrés « En bref » annoncent la question de chaque chapitre. Les encadrés « À retenir » en donnent le résultat. Les scores cv servent au choix des modèles ; dev et test désignent les ensembles réservés à leur évaluation.

Vue d’ensemble

Du corpus à une prédiction parmi huit émotions

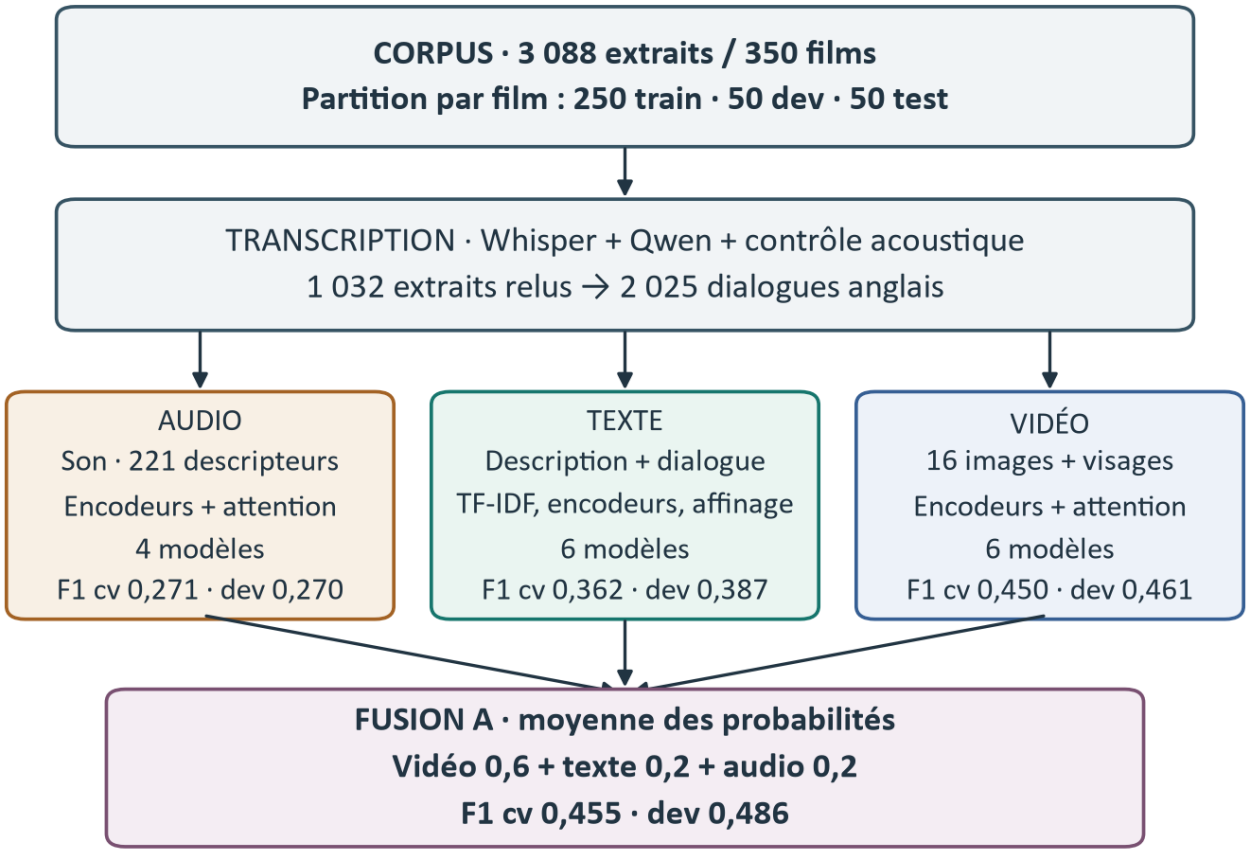


Figure 01 · Chaîne complète. Les scores affichés sont les F1 macro de validation croisée (cv) et de développement (dev). La transcription n'a pas de score d'erreur indépendant ; ses résultats sont des effectifs.

> **LE PRINCIPE DE COMPARAISON**
>
> N1 : mesures simples. N2 : encodeurs déjà entraînés, utilisés comme extracteurs de vecteurs. N3 : apprentissage supplémentaire. Pour chaque modalité, les meilleurs modèles sont combinés avant la fusion.

Un protocole unique. La validation croisée exclut des films entiers de chaque apprentissage. Le jeu de développement ne sert qu'à mesurer ; le jeu de test est évalué à la fin du point 5.

Résumé

Ce projet reconnaît la catégorie d'émotion (huit classes) d'extraits de film du corpus EmoVid à partir de trois sources : le texte (description de la scène et dialogues transcrits), le son et les images. Pour chaque modalité, nous allons du plus simple au plus riche : des descripteurs classiques (niveau N1), des modèles pré-entraînés utilisés comme extracteurs de vecteurs (N2), puis une partie apprise en plus (N3 : tête d'attention ou fine-tuning). Nous comparons ensuite trois façons de fusionner les modalités : combiner leurs probabilités (fusion tardive), mettre leurs vecteurs bout à bout (fusion précoce), ou apprendre un petit modèle multimodal à attention.

Tous les choix sont faits par validation croisée groupée par film sur l'ensemble d'apprentissage ; l'ensemble de développement ne sert qu'à mesurer, et l'ensemble de test n'est utilisé qu'une seule fois, à la fin. La vidéo est la meilleure modalité (F1 macro de 0,461 sur dev), devant le texte (0,387) et l'audio (0,270). La fusion retenue, une moyenne pondérée des probabilités des trois modalités, atteint **0,486 sur dev et 0,419 sur test** (hasard : 0,125). Avec seulement 2 207 extraits d'apprentissage, cette méthode simple fait mieux que les fusions qui apprennent davantage de paramètres.

1. Introduction

> **EN BREF**
>
> Reconnaître huit émotions dans des scènes de film. Trois sources sont comparées : son, texte et images. Les modèles simples servent de référence aux modèles pré-entraînés. La fusion combine ensuite leurs probabilités.

1.1 Objectif

Il s'agit de reconnaître, pour un extrait de film de quelques secondes, l'une des huit émotions suivantes : *amusement*, *anger* (colère), *awe* (émerveillement), *contentment* (satisfaction), *disgust* (dégoût), *excitement* (excitation), *fear* (peur) et *sadness* (tristesse). Chaque extrait offre trois sources d'information :

- les **images** de la vidéo ;
- la **bande son** : voix, musique, bruits ;
- du **texte** : une description de la scène fournie avec le corpus, et les dialogues, que nous avons transcrits.

Le travail suit les points de l'énoncé : analyse des données et partition (point 2), transcription (point 3), un modèle par modalité (point 4), fusion des modalités (point 5).

1.2 Organisation du travail et du dépôt

Tableau 01 · Répartition du travail et dossiers du dépôt

Point	Travail	Dossier	Auteur
2	Partition commune train / dev / test et statistiques	point2_partition/	commun à tous les groupes
3	Transcription vérifiée des dialogues	point3_transcription/	Hanchen LI
4	Modèle texte	point4_texte/	Hanchen LI
4	Modèle vidéo	point4_video/	Hanchen LI
4	Modèle audio	point4_audio/	Gaoussou Maouloud KONTA
5	Fusion des trois modalités	point5_fusion/	Gaoussou Maouloud KONTA
—	Rapport, figures et schémas	rapport/	groupe 4

Chaque dossier contient ses scripts numérotés dans l'ordre d'exécution, un README et un dossier resultats/ (scores, probabilités, matrices de confusion) versionné, ce qui permet de lire et de vérifier tous les chiffres de ce rapport sans relancer les calculs.

1.3 Plan du rapport

Après les données et leur partition (chapitre 2), le chapitre 3 présente la transcription. Le protocole commun vient ensuite (chapitre 4), juste avant les modèles audio, texte et vidéo (chapitres 5 à 7). La fusion et l'évaluation finale occupent le chapitre 8 ; les erreurs, les limites et les pistes suivent aux chapitres 9 et 10. Les annexes conservent les descripteurs, les configurations et les réglages nécessaires à la reproduction.

> **À RETENIR**
>
> La comparaison porte sur une même tâche et une même partition. La qualité du protocole compte autant que la complexité des modèles.

2. Données et partition (point 2)

> **EN BREF**
>
> Le corpus réunit 3 088 extraits issus de 350 films. La partition sépare les films, pas seulement les extraits. Les classes sont déséquilibrées et l'annotation privilégie le visuel. Ces deux propriétés guident l'évaluation.

2.1 Le corpus EmoVid

Le corpus est la section *movie* d'EmoVid (Qiu et al., 2025, arXiv 2511.11002), restreinte pour le projet. Les données disponibles comptent **350 films et 3 088 extraits**. Chaque extrait comprend :

- une vidéo MP4 (H264, 1280 × 720 pixels) ;
- la bande son séparée, en MP3 (44,1 kHz, stéréo) ;
- un fichier JSON contenant l'émotion, une description textuelle de la scène (*caption*), la durée et trois indicateurs d'image (luminosité, colorimétrie, teinte).

Tableau 02 · Caractéristiques des extraits

Caractéristique	Valeur
Durée des extraits	4 à 30 s, médiane 6,5 s, moyenne 8,2 s
Description (*caption*)	53 mots en moyenne
Extraits avec dialogue anglais (après transcription)	2 025 (66 %), 16 mots en moyenne
Extraits avec au moins un visage détecté	2 849 (92 %) ; 77 % des images contiennent un visage

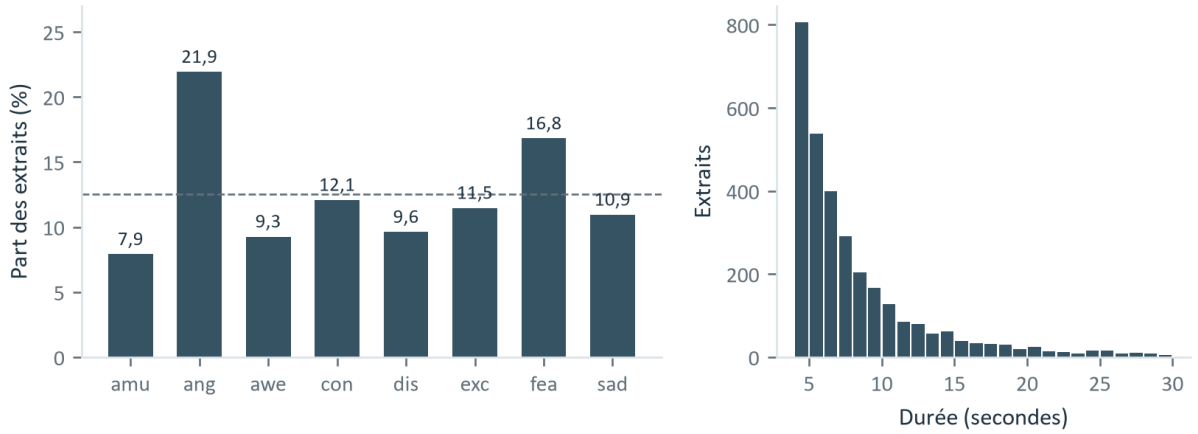


Figure 02 · Répartition des émotions dans le corpus (à gauche) et durée des extraits (à droite). La ligne pointillée indique 12,5 %, la part qu'aurait chaque émotion si les classes étaient équilibrées.

Les descriptions décrivent ce que l'on voit (par exemple « un homme aux cheveux roux, en chemise bleue, devant un grillage »), rarement ce que l'on ressent. Un tiers des extraits n'a aucun dialogue anglais.

2.2 Une annotation surtout visuelle

D'après l'article EmoVid, environ 80 % des émotions ont été attribuées automatiquement par un modèle vision-langage, NVILA-Lite-2B, qui ne voit que les images, puis contrôlées par des annotateurs. **Les étiquettes reflètent donc surtout le contenu visuel.** Ce point explique une grande partie des résultats : la vidéo sera la modalité la plus performante et l'audio la plus faible, non parce que le son ne porte pas d'émotion, mais parce que l'étiquette a été décidée en regardant les images.

2.3 Déséquilibre des classes et choix de la mesure

La classe la plus fréquente (*anger*, 21,9 %) est près de trois fois plus représentée que la plus rare (*amusement*, 7,9 %). Un modèle qui répondrait toujours *anger* aurait 22 % d'exactitude sans rien comprendre. Nous mesurons donc les modèles avec le **F1 macro** :

- pour une émotion donnée, la **précision** répond à « quand le modèle dit *peur*, a-t-il raison ? » et le **rappel** à « parmi les vraies peurs, combien le modèle en retrouve-t-il ? » ;
- le **F1** combine les deux : F1 = 2 × précision × rappel / (précision + rappel). Par exemple, une précision de 0,75 et un rappel de 0,60 donnent un F1 de 0,67 ;
- le **F1 macro** est la moyenne des F1 des huit émotions : chaque émotion compte autant, quelle que soit sa fréquence. Le repère de hasard retenu dans le rapport est 0,125 ; répondre toujours *anger* donne environ 0,04.

Pendant l'apprentissage, les classes sont **pondérées** : chaque extrait reçoit un poids inversement proportionnel à la fréquence de son émotion, pour que les émotions rares pèsent autant que les fréquentes.

2.4 Partition par film

Les extraits d'un même film partagent les acteurs, les décors, la lumière et la musique. Un modèle évalué sur un film déjà vu pendant l'apprentissage pourrait reconnaître ces éléments au lieu de l'émotion, et serait jugé trop favorablement. **La partition se fait donc par film** : aucun film n'est dans deux ensembles.

Chaque groupe a proposé une partition ; une seule a été retenue et est utilisée par tous les groupes. Ce n'est pas celle de notre groupe, qui visait 12,5 % de chaque émotion en dev et en test. La partition retenue garde au contraire les proportions du corpus dans chaque ensemble, à moins d'un demi-point près.

Tableau 03 · Partition retenue (statistiques calculées par point2_partition/statistiques.py)

	train	dev	test	total
Films	250	50	50	350
Extraits	2 207	442	439	3 088
amusement	7,9 %	7,9 %	8,0 %	7,9 %
anger	21,9 %	22,2 %	21,9 %	21,9 %
awe	9,3 %	9,0 %	9,1 %	9,3 %
contentment	12,0 %	12,2 %	12,3 %	12,1 %
disgust	9,6 %	9,7 %	9,8 %	9,6 %
excitement	11,4 %	11,5 %	11,6 %	11,5 %
fear	16,8 %	16,7 %	16,9 %	16,8 %
sadness	11,1 %	10,6 %	10,5 %	10,9 %

2.5 Nettoyage : les écrans de fin publicitaires

Certains extraits se terminent par un écran de la chaîne Movieclips (bandeau gris à gauche, bouton bleu à droite). Le script point4_video/00_nettoyer_pub.py les repère sans utiliser les étiquettes, en cherchant ces motifs jusqu'à la dernière image : 33 extraits sont concernés. Pour chacun, il enregistre l'instant fin_utile où l'écran commence ; les images comme le son sont arrêtés à cet instant dans tous les modules.

> **À RETENIR**
>
> 250 films et 2 207 extraits servent à apprendre. Les 50 films de dev et les 50 films de test restent séparés. Le F1 macro donne le même poids aux huit émotions.

3. Transcription des dialogues (point 3)

EN BREF

Deux systèmes de transcription indépendants se contrôlent. Des indices acoustiques et une séparation de la voix orientent les cas difficiles. Au total, 1 032 extraits ont été relus à l'écoute. Le corpus final contient 2 025 dialogues anglais.

Les dialogues ne sont pas fournis par le corpus. Il n'existe aucune transcription de référence pour nos extraits, et seulement environ 4 heures de parole : entraîner un système de reconnaissance de la parole est hors de portée. Nous utilisons donc des modèles de transcription pré-entraînés, tels quels, et tout le travail porte sur le **contrôle de leur qualité** : repérer quand ils se trompent ou inventent du texte.

3.1 Premier essai : un seul modèle

Whisper large-v3-turbo a d'abord été appliqué seul, avec une détection de parole (Silero VAD, pour ne pas transcrire les silences et la musique, sur lesquels Whisper invente parfois des phrases) et un filtrage des segments douteux, sur l'audio brut et sur la voix isolée par Demucs, un modèle de séparation de sources.

Tableau 04 · Premier essai de transcription sur les 3 088 extraits

Traitement	Extraits avec parole	Mots par extrait parlé	Textes modifiés par rapport au brut
Audio brut	2 119 (68,6 %)	14,9	—
Voix isolée (Demucs)	2 167 (70,2 %)	14,8	1 332 (43,1 %)
Filtre passe-bande 300–3 400 Hz	mêmes textes (12 extraits testés)	—	—

La séparation de la voix modifie 43 % des textes, mais sans référence on ne peut pas savoir lesquels sont meilleurs : elle retrouve parfois un mot couvert par la musique et en déforme parfois un autre. Le filtre fréquentiel ne sert à rien, la musique occupant la même bande que la voix. Conclusion : un seul modèle ne permet pas de savoir quand il se trompe. Il faut un moyen de **contrôler** les transcriptions.

3.2 Chaîne retenue : deux modèles qui se contrôlent

L'idée est simple : **deux modèles de familles différentes ne font pas les mêmes erreurs**. Quand ils écrivent le même texte et qu'on entend bien de la parole, le texte est très probablement juste ; quand ils divergent, un humain tranche. La chaîne compte neuf scripts.

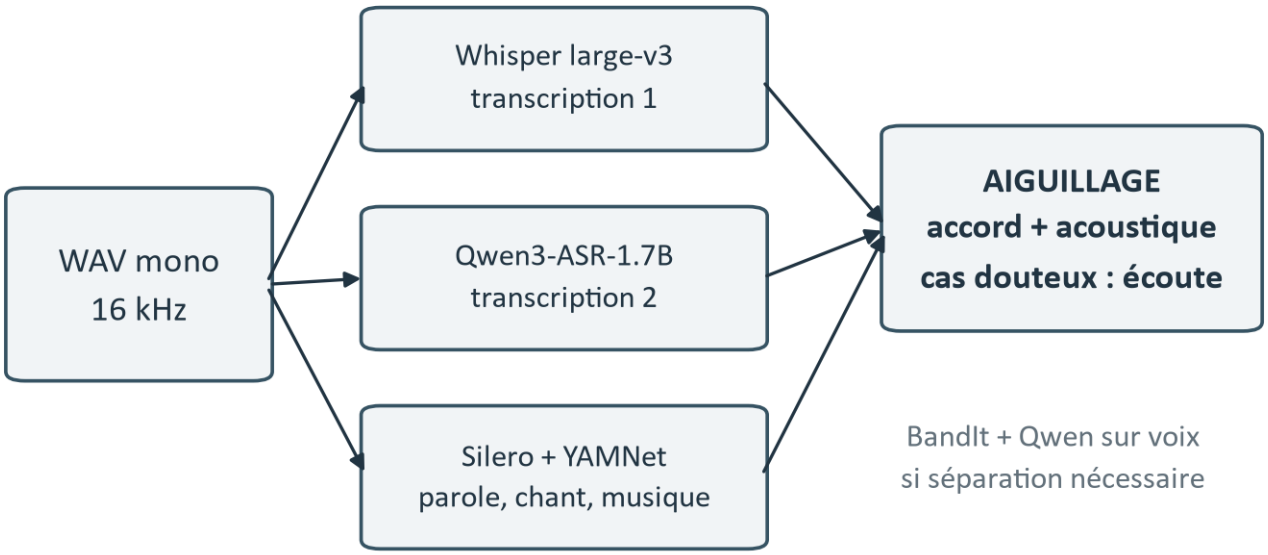


Figure 03 · Chaîne de transcription retenue. Deux modèles de transcription indépendants et deux détecteurs de sons alimentent un aiguillage à règles fixes ; les cas douteux sont écoutés et tranchés à la main.

1. **Préparation** (01) : chaque MP3 est converti en WAV mono à 16 kHz.
2. **Deux transcriptions** (02), sur l'extrait complet :
   - **Whisper large-v3** (OpenAI), exécuté avec whisper.cpp : recherche en faisceau sur 5 hypothèses, température 0 (réponse la plus probable), seuil de non-parole 0,6 ;
   - **Qwen3-ASR-1.7B** (Alibaba), un modèle de transcription d'une autre famille, exécuté avec llama.cpp, température 0.
3. **Indices acoustiques** (03), qui ne transcrivent rien mais disent ce que l'on entend :
   - **Silero VAD** mesure la **part de l'extrait où quelqu'un parle** ;
   - **YAMNet**, un classifieur de 521 catégories de sons (AudioSet), donne par fenêtres d'une seconde la probabilité de **parole**, de **vocalisations** (cris, rires, pleurs), de **musique** et de **chant** ; on garde le pic de chaque groupe.
4. **Séparation pour les cas difficiles** (04) : quand les deux modèles ne suffisent pas à conclure (désaccord, musique, texte vide malgré de la parole), la voix est séparée du reste par **BandIt** (fenêtres de 8 s), puis **Qwen retranscrit la voix seule**. C'est un troisième avis. On mesure aussi l'énergie de la voix récupérée : si elle est quasi nulle, il n'y avait sans doute pas de parole. 1 568 extraits sont passés par cette étape.
5. **Aiguillage** (05) : des règles fixes classent chaque extrait en *texte accepté*, *pas de dialogue* ou *à vérifier* (figure suivante).
6. **Vérification à l'écoute** (06) : les extraits douteux sont ouverts dans Label Studio, avec la vidéo, le son d'origine, la voix séparée et les trois transcriptions ; l'humain choisit la bonne, la corrige ou indique qu'il n'y a pas de dialogue.
7. **Nettoyage et langue** (07) : normalisation des caractères, suppression des symboles de musique (), puis détection de la langue (langid, score ≥ 0,9 sur au moins 5 mots), confrontée aux langues annoncées par Whisper et Qwen. **Seul l'anglais est gardé**, car les modèles texte utilisés ensuite sont anglais ; un dialogue dans une autre langue est laissé vide.
8. **Export et corpus** (08, 09) : la transcription finale est jointe à la partition, à l'émotion et à la description pour former corpus.csv.

3.3 Les règles d'aiguillage

Pour comparer deux transcriptions, on les ramène à une **liste de mots** (minuscules, sans ponctuation ; des marqueurs comme « [music] » ou « silence » comptent comme un texte vide), puis on vérifie cinq conditions :

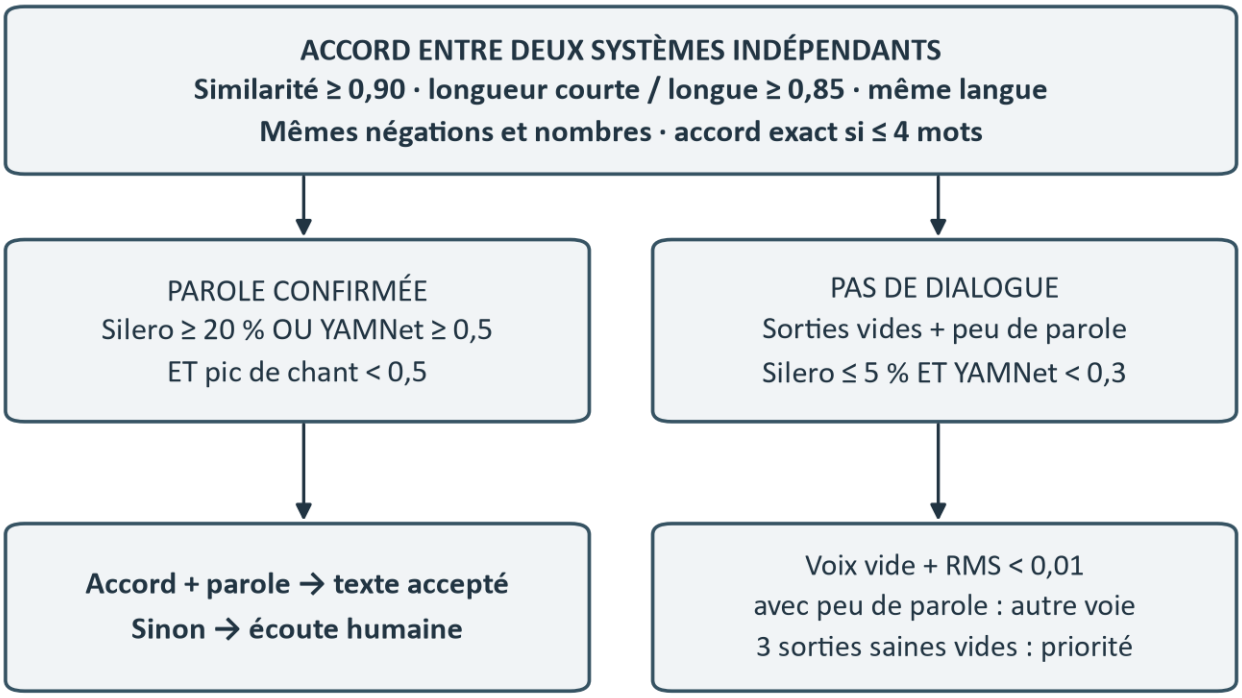


Figure 04 · Règles d'aiguillage (simplifiées). Un extrait n'est accepté sans écoute que si deux transcriptions indépendantes concordent et que la parole est confirmée par les détecteurs de sons.

- la **similarité** des deux listes (part des mots communs dans le même ordre) est d'au moins 0,90 ;
- le **rapport de longueur**, texte court / texte long, est au moins égal à 0,85 ;
- les deux modèles annoncent la **même langue** ;
- elles contiennent exactement les **mêmes négations et les mêmes nombres** (*no*, *not*, *never*, *nothing*… et tous les chiffres) : une seule différence de ce type change le sens de la phrase ;
- pour une phrase de 4 mots ou moins, l'accord doit être **exact**.

La parole est **confirmée** si Silero détecte de la parole sur au moins 20 % de l'extrait ou si YAMNet donne une probabilité de parole d'au moins 0,5, et si le pic de chant YAMNet reste inférieur à 0,5 (un texte chanté peut être une chanson, pas un dialogue). Un extrait est classé *pas de dialogue* si les transcriptions sont vides **et** que les détecteurs entendent peu de parole (Silero ≤ 5 % et YAMNet < 0,3), ou, toujours avec peu de parole détectée, si la voix séparée est vide et si son rapport d'amplitude RMS au mélange est inférieur à 0,01. RMS désigne l'amplitude quadratique moyenne. Une règle prioritaire classe aussi « pas de dialogue » les trois sorties saines et strictement vides. Un accord original valide et soutenu par l'audio est prioritaire : une séparation moins bonne ne l'annule pas.

Tableau 05 · Résultat de l'aiguillage (version finale des scripts)

Sortie	Extraits	Détail
Texte accepté	1 267	1 237 où Whisper et Qwen concordent, 30 où Whisper et Qwen sur la voix séparée concordent
Pas de dialogue	829	modèles vides et peu de parole, ou voix séparée vide et sans énergie
À vérifier	992	principales raisons : pas de paire concordante (793), textes différents (724), longueurs différentes (401), négation ou nombre différent (188)

3.4 Résultats

Tableau 06 · Décisions prises à l'écoute et corpus final

Résultat	Extraits
Écoutés et tranchés à la main	1 032
dont texte de Qwen retenu	690
dont texte de Whisper retenu	234
dont pas de dialogue	63
dont texte de Qwen sur la voix séparée	28
dont texte corrigé à la main	17
Avec dialogue anglais (corpus final)	2 025 (66 %)
Sans dialogue	994
Autre langue ou incertain	69

Parmi les décisions humaines, le texte de Qwen a été retenu environ trois fois plus souvent que celui de Whisper (690 contre 234). Les 992 cas du routage final et les 1 032 décisions humaines correspondent à deux comptages distincts ; leur différence ne constitue pas une mesure d'erreur. Le résultat, point3_transcription/resultats/corpus.csv, réunit pour chaque extrait la partition, l'émotion, la description, le dialogue, un indicateur « dialogue présent », la langue et la durée. C'est l'entrée commune de tous les modèles du point 4. Depuis le dépôt, il se reconstruit à l'identique à partir des décisions enregistrées (07 à 09, quelques secondes).

3.5 Limites

Les extraits non relus à la main (2 056, avec ou sans dialogue) peuvent contenir des erreurs, même quand deux modèles concordent ; aucun taux d'erreur sur les mots n'a été mesuré, faute de référence indépendante. Les cris, rires et pleurs ne sont pas des mots et ne sont pas transcrits, alors qu'ils portent beaucoup d'émotion : c'est le rôle du modèle audio de les capter.

> **À RETENIR**
>
> L'accord entre systèmes sert à trier les cas, sans garantir une transcription parfaite. Les seuils sont fixes ; les désaccords passent par l'écoute humaine. Aucun taux d'erreur lexical indépendant n'est disponible.

4. Protocole commun des modèles

EN BREF

Tous les réglages sont choisis sur train par validation croisée à cinq plis, groupés par film. Chaque prédiction hors pli vient d'un modèle qui n'a jamais vu le film. Dev ne sert qu'à mesurer. Les modèles d'émotion utilisent les vecteurs des encodeurs.

Cette partie décrit la méthode suivie par les trois modalités et par la fusion. Elle est commune à tout le projet : c'est elle qui rend les scores comparables et qui permet de fusionner proprement.

4.1 Trois ensembles, trois rôles

- **train** (250 films, 2 207 extraits) : sert à **apprendre** les modèles et à **faire tous les choix** (réglages, couches, nombre de modèles combinés, poids de la fusion), par validation croisée.
- **dev** (50 films, 442 extraits) : sert **uniquement à mesurer** les modèles retenus. Aucun choix n'y est fait.
- **test** (50 films, 439 extraits) : utilisé **une seule fois**, à la toute fin, pour le système final.

Pourquoi ne pas choisir les réglages sur dev ? Parce que 50 films, c'est peu : en essayant des dizaines de réglages et en gardant le meilleur sur dev, on garde souvent celui qui a eu de la chance sur ces 50 films. Le module texte l'a mesuré : réglé en regardant dev, son système N2 affichait 0,405 sur dev ; réglé proprement en validation croisée, 0,366. Les 4 points d'écart n'étaient que de la chance.

4.2 La validation croisée par film

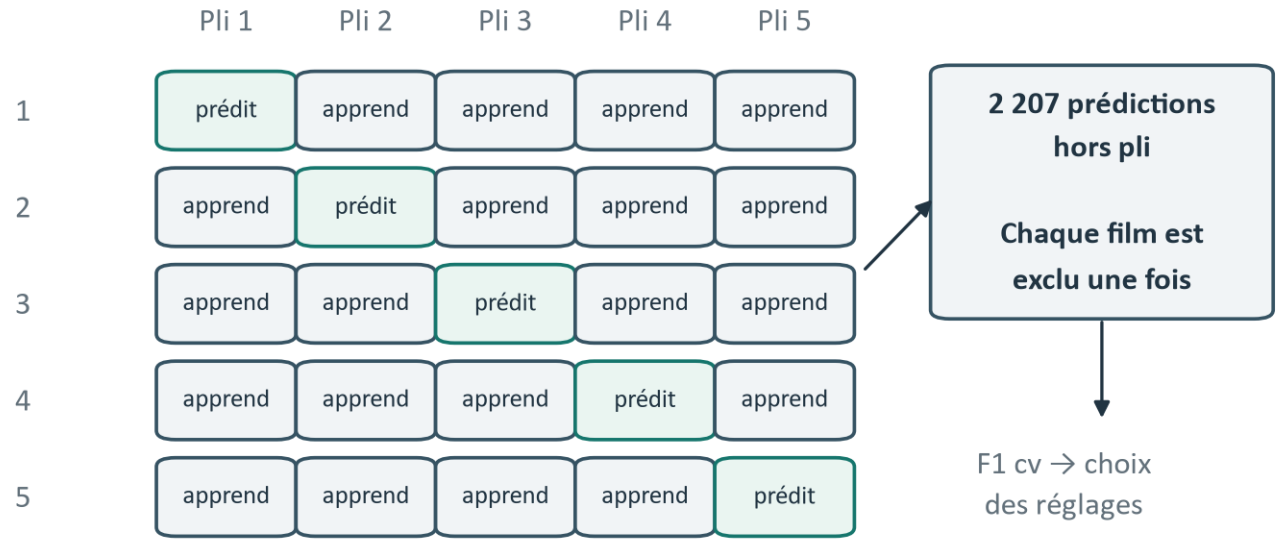


Figure 05 · Validation croisée à 5 plis groupés par film. Chaque paquet de films est prédit une fois par un modèle appris sur les quatre autres ; on obtient ainsi une prédiction « honnête » pour chacun des 2 207 extraits de train.

1. Les 250 films de train sont répartis en **5 paquets** d'environ 50 films (environ 440 extraits chacun), avec GroupKFold de scikit-learn, qui ne fait pas de tirage au hasard : les paquets sont **les mêmes dans les trois modalités** (même corpus.csv, même ordre).
2. **Tour 1** : on apprend un modèle sur les paquets 2 à 5, puis il prédit les extraits du paquet 1. **Tour 2** : un nouveau modèle apprend sur les paquets 1, 3, 4 et 5, puis prédit le paquet 2. Et ainsi de suite jusqu'au tour 5.

3. À la fin, **chacun des 2 207 extraits a été prédit exactement une fois**, par un modèle qui n'avait jamais vu son film.

À chaque tour, tout ce qui s'apprend est réappris sur les quatre paquets d'apprentissage seulement : la standardisation des variables (moyenne et écart-type), le classifieur, le TF-IDF du texte.

4.3 Les prédictions hors pli et le F1 cv

Les prédictions obtenues à l'étape 3 s'appellent les **prédictions hors pli** (un « pli » est un paquet). Pour chaque extrait de train, ce sont les huit probabilités données par le modèle du tour où son paquet était mis de côté. Elles servent à trois choses :

- calculer le **F1 cv** : on compare ces 2 207 prédictions aux vraies émotions et on calcule le F1 macro. C'est le chiffre « F1 cv » des tableaux de ce rapport ;
- choisir les réglages (paragraphe suivant) ;
- apprendre les **combinaisons** de modèles et la **fusion** sans toucher à dev.

Une variante est utilisée pendant la recherche des réglages : on calcule un F1 macro sur chacun des cinq paquets, puis la moyenne des cinq. Les deux calculs donnent presque le même nombre (par exemple 0,209 et 0,212 pour le N1 audio), mais pas exactement, car le F1 n'est pas une somme : la moyenne de cinq F1 n'est pas le F1 de l'ensemble. Cela explique quelques écarts au millième près entre certains tableaux des README.

4.4 Comment on choisit un réglage

Pour comparer deux réglages (par exemple deux couches d'un encodeur, ou deux valeurs de régularisation), on fait passer chacun par la validation croisée complète et on garde celui qui a le meilleur F1 cv. Deux outils sont utilisés :

- la **recherche sur grille** (GridSearchCV) quand il y a peu de valeurs à essayer (par exemple 9 valeurs de C × avec ou sans pondération des classes) ;
- **Optuna**, quand il y a beaucoup de réglages continus (taille d'un réseau, taux d'apprentissage, dropout : mise à zéro aléatoire de neurones…) : il propose un réglage, la validation croisée le note, et il s'en sert pour proposer le suivant. Nous lui accordons 30 essais (25 pour les SVM de la vidéo, 20 pour ceux de l'audio).

Comme les réglages sont choisis en regardant ces mêmes prédictions hors pli, le F1 cv du réglage retenu est légèrement optimiste. C'est pourquoi on contrôle ensuite sur dev, qui n'a servi à rien.

4.5 Le modèle final et la mesure sur dev

Une fois le réglage choisi, on apprend un **modèle final** avec ce réglage sur **les 250 films de train**. Ce modèle prédit dev (F1 dev) et test. On n'utilise jamais ses prédictions de train pour l'évaluation : il a appris sur ces extraits, son score y serait faussement excellent. Chaque modèle enregistre donc deux sortes de prédictions, toutes deux « honnêtes », dans un fichier resultats/probas_<modèle>.npz :

Tableau 07 · Contenu d'un fichier de probabilités

Champ	Contenu	Produit par
probabilites_hors_pli	8 probabilités pour chaque extrait de train (NaN ailleurs)	les 5 modèles de la validation croisée
probabilites	8 probabilités pour les 3 088 extraits ; seules celles de dev et test sont utilisées	le modèle final appris sur tout train
video_id, partition, emotions	identifiants, ensemble, ordre des 8 émotions	—

4.6 Intervalles de confiance par films

Pour savoir si une différence de score entre deux systèmes est réelle, nous rééchantillonnons les films : 2 000 fois, on tire 50 films avec remise parmi ceux de dev, on recalcule la différence de F1 macro, et on garde l'intervalle qui contient 95 % des différences. Si cet intervalle ne contient pas 0, le gain est significatif. On tire les **films** et non les extraits, parce que les extraits d'un même film se ressemblent et ne sont pas des observations indépendantes.

4.7 Les trois niveaux de méthodes et la combinaison

Chaque modalité suit le même parcours :

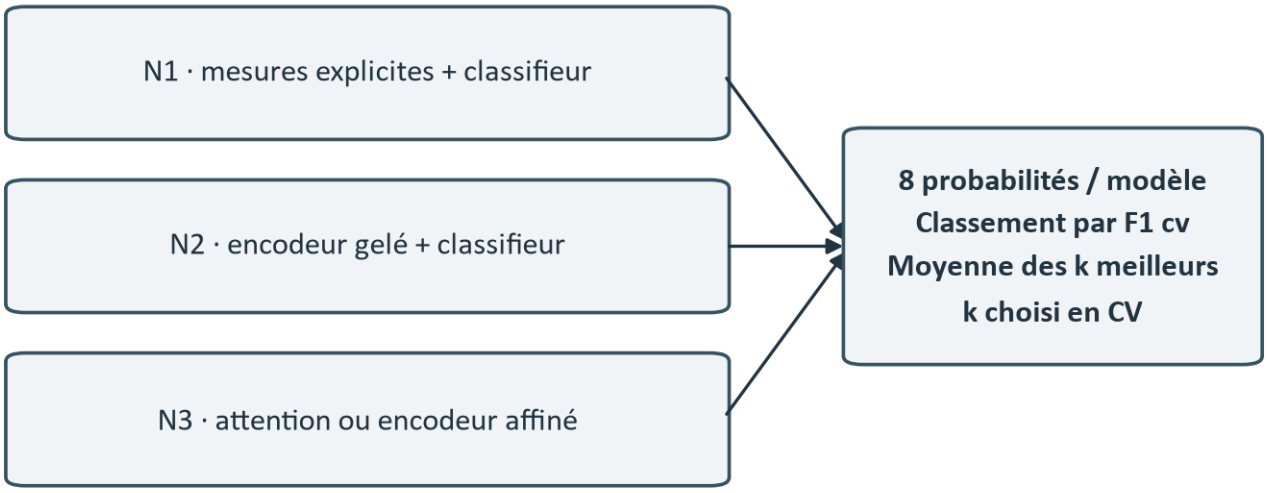


Figure 06 · Parcours d'une modalité : trois niveaux de méthodes, chacun produisant des probabilités, puis une combinaison des meilleurs modèles.

- **N1 — descripteurs classiques** : des mesures calculées « à la main » (TF-IDF pour le texte, couleurs pour la vidéo, descripteurs acoustiques pour le son), suivies d'une régression logistique ;
- **N2 — encodeurs pré-entraînés gelés** : un modèle pré-entraîné, déjà appris sur de grandes quantités de données, transforme l'extrait en vecteur ; seul un classifieur posé sur ce vecteur est appris ;
- **N3 — une partie apprise en plus** : soit une **tête d'attention** qui apprend à pondérer les moments ou les images de l'extrait (audio, vidéo), soit le **fine-tuning** du modèle entier (texte) ;
- **combinaison** : on fait la moyenne des probabilités des *k* meilleurs modèles.

La combinaison fonctionne ainsi :

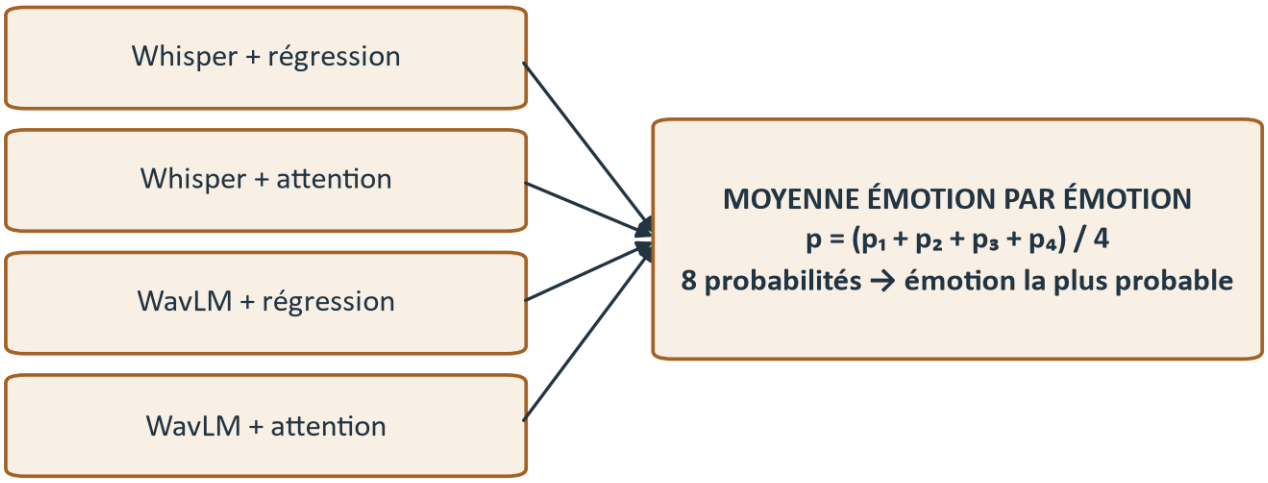


Figure 07 · Combinaison des k meilleurs modèles, sur l'exemple de l'audio (k = 4). Les probabilités sont moyennées émotion par émotion ; l'émotion retenue est celle de plus forte probabilité moyenne.

1. chaque modèle donne 8 probabilités par extrait ;
2. on classe tous les modèles de la modalité par F1 cv, du meilleur au moins bon ;
4. pour k = 1, 2, 3..., on fait la moyenne des probabilités des k premiers, émotion par émotion, et on retient pour chaque extrait l'émotion de plus forte probabilité moyenne ;
4. on calcule le F1 cv de chaque moyenne (sur les prédictions hors pli) et on garde le meilleur k.

Une moyenne n'a aucun paramètre à apprendre : seul k est choisi. Elle fonctionne parce que des modèles différents ne se trompent pas sur les mêmes extraits ; leurs erreurs se compensent en partie.

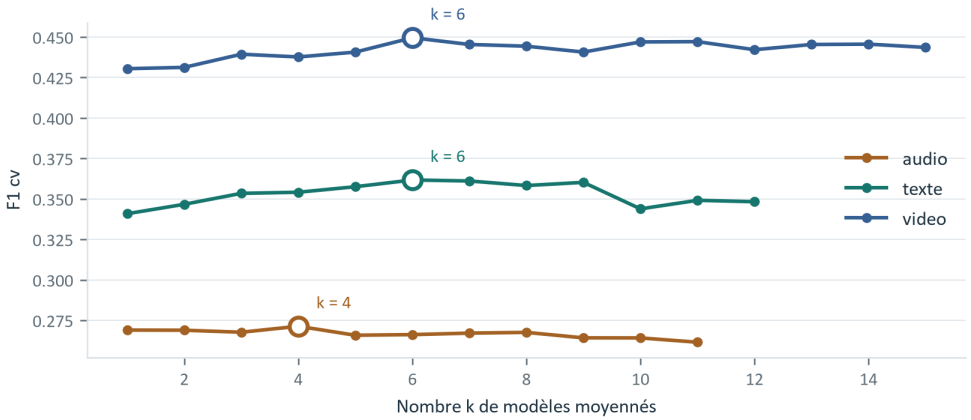


Figure 08 · F1 cv de la moyenne des k meilleurs modèles, pour chaque modalité. Le cercle creux marque le k retenu : 4 pour l'audio, 6 pour le texte et la vidéo.

4.8 Encodeurs et vecteurs : le vocabulaire

Les modèles pré-entraînés utilisés dans ce projet sont des réseaux de type Transformer. Trois notions sont utiles pour la suite.

- **Encodeur.** Un encodeur lit du son, une image ou du texte et produit des vecteurs, c'est-à-dire des listes de valeurs qui résument l'entrée. Pour la **classification des émotions** (points 4 et 5), seuls les encodeurs sont utilisés : **aucun décodeur n'est utilisé**. La transcription du point 3 constitue une étape distincte de préparation des dialogues.

- **Gelé.** Un encodeur gelé n'est jamais modifié : ses poids restent ceux du pré-entraînement, il ne voit aucune étiquette d'émotion, et il ne tourne qu'**une seule fois** sur les 3 088 extraits. Ses vecteurs sont enregistrés sur disque, puis redistribués dans les plis de la validation croisée. Passer dev et test dans un encodeur gelé dès le début n'est donc pas une fuite d'information : c'est une traduction fixe des données en vecteurs.
- **Couches.** Un encodeur est une **pile de couches** : chacune transforme les vecteurs de la précédente. On peut lire les vecteurs produits par n'importe quelle couche, pas seulement la dernière. Les premières couches restent proches du signal brut ; les dernières se spécialisent dans la tâche d'origine du modèle (pour Whisper, transcrire). Nous utilisons les **vecteurs** (les sorties) des couches, jamais leurs **poids** (les paramètres internes).

> **À RETENIR**
>
> F1 cv pour choisir, dev pour contrôler, test pour l'évaluation finale. Standardisation, vocabulaire et classifieurs sont appris dans chaque pli. Les prédictions hors pli rendent possible une fusion sans réglage sur dev.

5. Modèle audio (point 4)

> **EN BREF**
>
> Le son devient d'abord 221 descripteurs, puis des vecteurs d'encodeurs gelés. Une tête d'attention peut pondérer 16 tranches temporelles. Quatre modèles sont finalement moyennés. Le système obtient 0,271 en F1 cv et 0,270 sur dev.

5.1 Préparation du son

Pour tous les niveaux, le MP3 stéréo (44,1 kHz) est converti en **mono à 16 000 échantillons par seconde** (48 000 pour CLAP), arrêté avant l'écran de fin publicitaire et coupé à 30 secondes au plus. On obtient une **forme d'onde** : une suite de nombres qui décrit la pression de l'air au cours du temps.

5.2 N1 : descripteurs acoustiques et régression logistique

Ce que sont les descripteurs

Un **descripteur** est une mesure calculée directement sur le son, par une formule connue, sans apprentissage. Ils décrivent la voix (hauteur, intensité, qualité), le timbre et la musique. Nous en calculons deux familles.

eGeMAPS (*extended Geneva Minimalistic Acoustic Parameter Set*, Eyben et al., 2016), calculé avec l'outil openSMILE. C'est un jeu de référence volontairement **petit**, conçu par des chercheurs en émotion vocale pour que les études soient comparables. Il donne **88 valeurs** par extrait :

- le son est découpé en **trames** très courtes (20 à 60 ms), une toutes les 10 ms ;
- sur chaque trame, openSMILE mesure **25 descripteurs de bas niveau**. Fréquence : hauteur de la voix (F0), jitter (micro-variations de hauteur), fréquences et largeurs des formants F1 à F3 (résonances de la bouche et de la gorge). Énergie : intensité perçue, shimmer (micro-variations d'intensité), rapport harmoniques sur bruit (HNR, voix claire ou soufflée). Spectre : pentes du spectre, *alpha ratio* et indice de Hammarberg (répartition de l'énergie entre graves et aigus), différences d'harmoniques H1-H2 et H1-A3 (tension de la voix), MFCC 1 à 4, flux spectral ;
- chaque descripteur est ensuite **résumé sur tout l'extrait** : moyenne et coefficient de variation pour tous, et pour la hauteur et l'intensité aussi les centiles 20, 50 et 80, l'écart entre centiles et la vitesse des montées et des descentes ;

- s'y ajoutent des mesures de **rythme** : nombre de pics d'intensité par seconde, nombre et durée des segments voisés (où la voix vibre) et des pauses.

librosa, une bibliothèque Python d'analyse audio, complète eGeMAPS avec des mesures plus générales, qui décrivent aussi la musique et les bruits : 20 **MFCC** (coefficients qui résument la forme du spectre, donc le « timbre ») et leurs **dérivées** (comment le timbre change), 12 **chroma** (l'énergie de chacune des 12 notes de la gamme), 7 bandes de **contraste spectral** (pics contre creux du spectre), le **centroïde** (son clair ou sourd), la largeur de bande, le *rolloff*, la **platitude** (bruit ou son tonal), l'**énergie**, le taux de **passages par zéro** (son bruité ou aigu) et la force des **attaques** (chocs, coups). Pour chacune, on garde la moyenne et l'écart-type dans le temps, plus le **tempo**.

Tableau 08 · Composition des 221 descripteurs du N1 audio

Bloc	Détail	Nombre
eGeMAPS	25 descripteurs par trame résumés sur l'extrait, et rythme	88
MFCC	20 coefficients × (moyenne, écart-type)	40
Dérivées des MFCC	20 × 2	40
Chroma	12 notes × 2	24
Contraste spectral	7 bandes × 2	14
Centroïde, largeur de bande, rolloff, platitude	4 × 2	8
Énergie, passages par zéro, attaques	3 × 2	6
Tempo	battements par minute	1
Total		**221**

Un mot sur un chiffre parfois cité : eGeMAPS ne contient pas « plusieurs milliers » de descripteurs. Le grand jeu d'openSMILE, ComParE 2016, en compte 6 373. Avant le résumé, on dispose aussi d'environ 16 000 valeurs pour un extrait de 6,5 s (25 descripteurs × 650 trames). Nous utilisons le jeu résumé de 88 valeurs, adapté à nos 2 207 exemples : 6 373 variables pour 2 207 extraits mèneraient tout droit au surapprentissage.



Figure 09 · Du son aux 221 descripteurs, puis à la régression logistique. Tout est calculé une fois par extrait ; seule la dernière étape est apprise.

Comment la régression logistique les utilise

1. **Standardisation** : chacun des 221 descripteurs est centré et réduit (moyenne 0, écart-type 1), avec la moyenne et l'écart-type calculés sur les extraits d'apprentissage. Sans cela, un descripteur exprimé en hertz (des centaines) écraserait un descripteur compris entre 0 et 1.
2. **Un score par émotion** : pour chaque émotion e, le modèle calcule score(e) = b(e) + w(e,1) × x1 + w(e,2) × x2 + … + w(e,221) × x221, où x1 à x221 sont les descripteurs standardisés. Il y a donc un poids w par descripteur **et par émotion** : 221 × 8 poids + 8 biais, soit 1 776 paramètres.

3. **Des probabilités** : la fonction *softmax* transforme les 8 scores en 8 probabilités positives qui font 1 au total. L'émotion prédite est celle de plus forte probabilité.
4. **L'apprentissage** cherche les poids qui donnent une forte probabilité à la vraie émotion (entropie croisée), avec deux réglages choisis en validation croisée :
   - **C**, l'inverse de la force de la régularisation : un petit C pousse les poids vers 0, ce qui limite le surapprentissage. C est essayé parmi 9 valeurs, de 0,0001 à 1 ;
   - la **pondération des classes** (avec ou sans).

Réglage retenu : **C = 0,003** (régularisation forte), classes pondérées. Résultat : **F1 cv 0,212, F1 dev 0,224**, exactitude dev 22,6 %. C'est mieux que le hasard (0,125), mais modeste.

Quels descripteurs contribuent à la prédiction ?

Nous avons mesuré l'importance de chaque **famille** de descripteurs par permutation, en validation croisée. Dans chaque pli, on mélange au hasard les valeurs d'une famille entre les extraits du paquet prédit (ce qui « brouille » l'information de la famille sans changer sa distribution), puis on mesure la baisse du F1 macro. Plus la baisse est forte, plus le modèle utilisait cette famille.

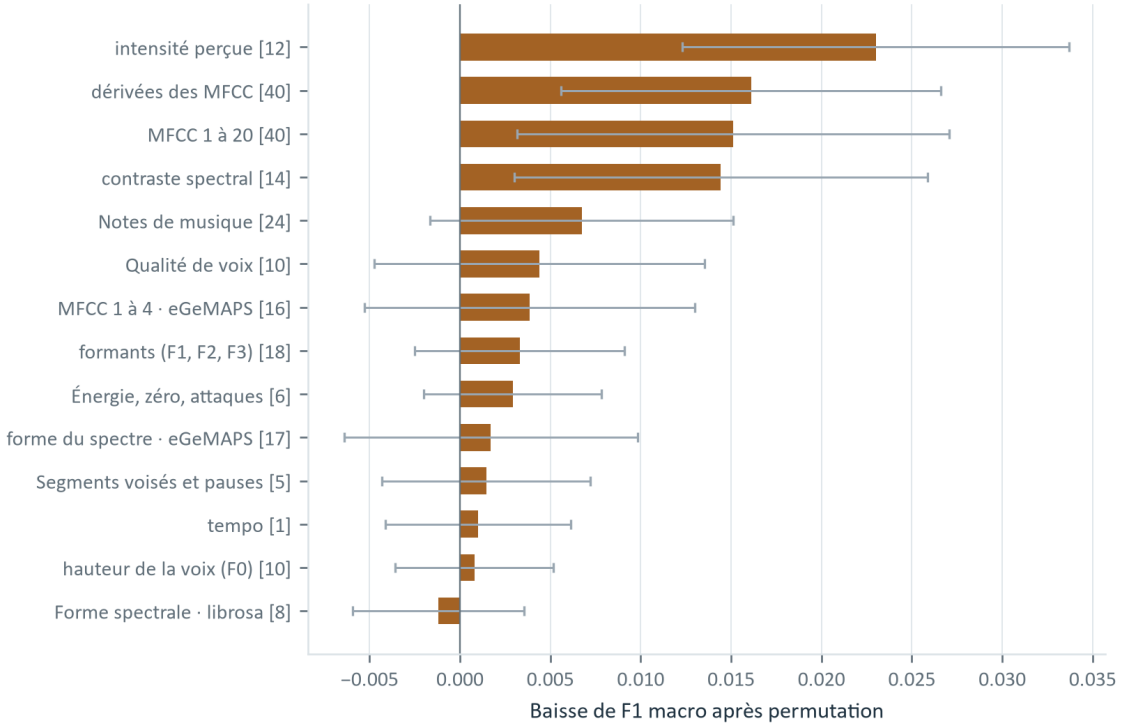


Figure 10 · Importance des familles de descripteurs du N1 audio : baisse du F1 macro quand la famille est brouillée, en moyenne sur les 5 plis (barre d'erreur : écart-type entre plis). Le nombre de descripteurs de chaque famille est indiqué entre crochets.

- **L'intensité perçue** (volume de la voix et du son, ses variations, pics d'intensité par seconde) est la famille la plus utile : la brouiller fait perdre 0,023 de F1, soit plus de 10 % du score du N1.
- Viennent ensuite le **timbre** : MFCC, leurs dérivées et le contraste spectral. Ces descripteurs captent l'ensemble du son (voix, musique, bruitages), ce qui est logique pour des scènes de film.
- La **hauteur de la voix** (F0), pourtant classique en émotion vocale, n'apporte presque rien ici : dans les films, la voix est souvent couverte par la musique et les effets, et un tiers des extraits n'a pas de dialogue.

Les coefficients du modèle appris sur tout train confirment cette image. Les descripteurs aux poids moyens les plus forts (en valeur absolue, toutes émotions confondues) sont la moyenne du premier MFCC (l'énergie globale du spectre), une dérivée de MFCC, le nombre de **pics d'intensité par seconde** (le débit, les syllabes, les chocs), le contraste spectral des graves, et deux mesures de **qualité de voix** (variabilité du jitter et de la différence H1-A3). Par émotion, les poids les plus positifs sont parlants : l'**intensité médiane** pour

amusement, la **variabilité des descentes d'intensité** pour *excitement*, le **flux spectral des parties non voisées** (bruits, souffles) pour *fear*, et les **pics d'intensité** pour *awe*.

Une précision s'impose : les descripteurs d'une même famille sont corrélés entre eux, et la régularisation répartit les poids entre descripteurs voisins. Il faut donc lire les poids individuels avec prudence ; l'importance par famille, mesurée par permutation, est plus fiable. Les tableaux complets sont dans figures/importance_familles_n1.csv et descripteurs_principaux_n1.csv.

5.3 N2 : encodeurs pré-entraînés gelés

Les cinq encodeurs

Tableau 09 · Les cinq encodeurs audio comparés en N2

Encodeur	Pré-entraînement	Entrée	Couches	Taille des vecteurs
Whisper large-v3 (OpenAI), encodeur seul	transcription de parole multilingue (millions d'heures)	spectrogramme log-mel, 128 bandes	32	1 280
WavLM large (Microsoft)	parole, auto-supervisé	forme d'onde brute	24	1 024
wav2vec2 émotion (audEERING)	parole, affiné sur valence, éveil, dominance	forme d'onde brute	12	1 024
AST (MIT)	527 catégories de sons d'AudioSet	spectrogramme, fenêtres de 10 s	12	768
CLAP (LAION), branche audio	association son-texte, musique et parole	son à 48 kHz, fenêtres de 10 s	vecteur final	512

Les cinq couvrent trois façons de « comprendre » le son : la parole (Whisper, WavLM), l'émotion dans la voix (wav2vec2 émotion) et les sons et la musique (AST, CLAP). Un sixième, MERT (musique), a été écarté parce qu'il exige d'exécuter du code téléchargé.

Ce que l'on prend de chaque modèle

Nous n'utilisons que la **partie encodeur** de chaque modèle :

- **Whisper** : son **décodeur n'est pas utilisé** pour classer les émotions. On garde seulement l'encodeur, qui transforme le son en vecteurs ;
- **WavLM et wav2vec2** sont chargés sans leur tête finale : seulement la pile de couches ;
- **AST** : on lit les couches de son encodeur ; sa tête de classification ne sert qu'à produire les 527 probabilités AudioSet, testées à part comme descripteurs ;
- **CLAP** : seulement la branche audio, qui donne un vecteur final par fenêtre de 10 s.

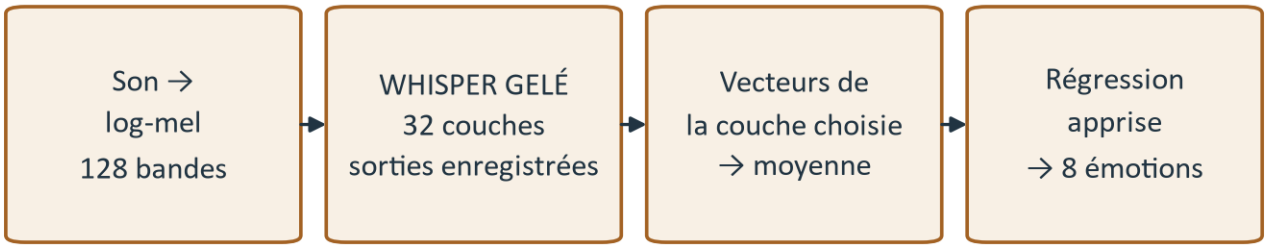


Figure 11 · N2 audio : l'encodeur gelé de Whisper. Le son traverse les 32 couches une seule fois ; on enregistre les vecteurs de chaque couche, on les résume dans le temps, puis une régression logistique apprend à reconnaître l'émotion. Le décodeur n'est pas utilisé.

Du son au vecteur, couche par couche

1. Le son est préparé comme le demande chaque modèle (spectrogramme log-mel pour Whisper et AST, forme d'onde normalisée pour WavLM et wav2vec2).
2. Il traverse l'encodeur **une seule fois**, sur la carte graphique, en demandant la sortie de **toutes** les couches (*hidden states*). Chaque couche rend une suite de vecteurs dans le temps : pour Whisper, un vecteur de 1 280 valeurs toutes les 20 ms, soit environ 325 vecteurs pour un extrait de 6,5 s.
3. Pour chaque couche, cette suite est résumée par sa **moyenne**, seule ou complétée par son **écart-type**, dans le temps : un vecteur par couche et par extrait.
4. Tout est enregistré sur disque (couches_whisper.npy : 3 088 extraits × 33 sorties de couche × 2 560 valeurs). Ce calcul a pris 12,8 minutes pour Whisper.
5. **Ensuite seulement**, avec les étiquettes, on donne les vecteurs d'une couche à un classifieur, évalué en validation croisée.

Les 76 configurations

Pour chaque encodeur, on avance **étape par étape**, en gardant à chaque étape le meilleur choix en F1 cv :

Tableau 10 · Les étapes de la recherche du N2 audio

Étape	Question	Ce qu'on essaie	Classifieur	Configurations par encodeur
A1	Quelle couche ?	7 couches réparties de la première à la dernière + la moyenne de toutes les couches	régression logistique	8
A2	Quel résumé dans le temps ?	moyenne + écart-type (la moyenne seule est déjà en A1)	régression logistique	1
B	Ajouter des descripteurs ?	N1, probabilités AudioSet, les deux	régression logistique	3
D	Un autre classifieur ?	analyse discriminante (LDA, séparation statistique des classes) et SVM (classifieur à marge maximale), sur « sans ajout » et sur le meilleur ajout	LDA, SVM	4

Cela fait 16 configurations pour chacun des quatre encodeurs à couches (64), 9 pour CLAP (pas de couches : A2, B et D), et 3 pour les probabilités AudioSet seules (régression logistique, LDA, SVM) : **76** au total. Chaque configuration contient elle-même une recherche de réglages en validation croisée (C pour la régression logistique, 20 essais Optuna pour le SVM), soit plusieurs centaines d'apprentissages. Le détail figure en annexe B.

Tableau 11 · Meilleure configuration de chaque encodeur (F1 cv : moyenne par pli)

Sortie retenue	Couche	Ajout	Classifieur	F1 cv	F1 dev
Whisper	16 sur 32	—	régression logistique	**0,265**	0,267
WavLM	moyenne des couches	N1	régression logistique	0,256	0,240
wav2vec2 émotion	moyenne des couches (+ écart-type)	N1 + AudioSet	régression logistique	0,249	0,263
CLAP	—	—	régression logistique	0,245	0,229
AST	4 sur 12	—	régression logistique	0,241	0,219
AudioSet seul	—	—	régression logistique	0,213	0,214

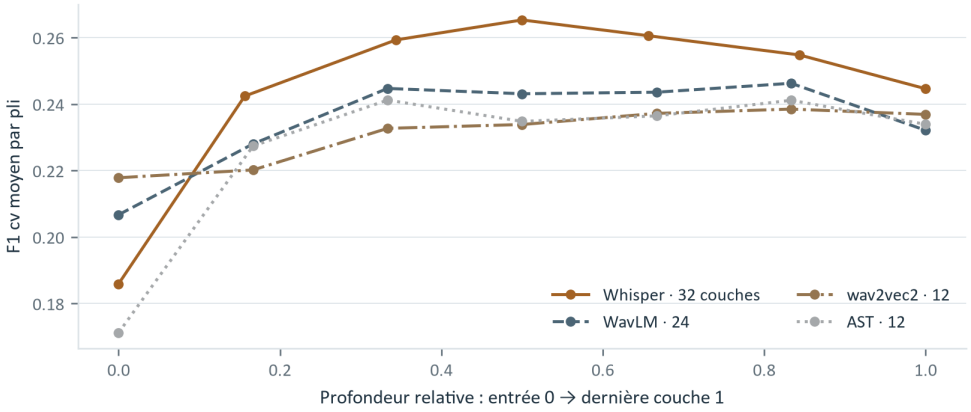


Figure 12 · F1 cv selon la couche de l'encodeur, pour les quatre encodeurs à couches (régression logistique, moyenne dans le temps). L'axe horizontal ramène toutes les piles à la même échelle : 0 pour l'entrée, 1 pour la dernière couche.

Ce que l'on retient :

- **Les couches du milieu sont les plus utiles.** Pour Whisper : 0,186 pour l'entrée (couche 0), 0,242 pour la couche 5, 0,265 pour la couche 16, puis 0,245 pour la dernière. Whisper a été entraîné à transcrire : ses dernières couches ne gardent que ce qui sert à écrire les mots et « oublient » le ton de la voix, alors que l'émotion est justement dans le ton. Même phénomène pour AST, dont la meilleure couche est la 4 sur 12.
- **Les modèles de parole dépassent les modèles de sons et de musique**, et même le modèle affiné sur l'émotion vocale ne bat pas Whisper : il a été entraîné sur des voix enregistrées en studio, avec d'autres catégories.
- **La régression logistique est la meilleure partout** ; le SVM tombe à 0,16–0,20 une fois calibré pour donner des probabilités.
- **Ajouter les descripteurs N1 ou AudioSet n'apporte presque rien** une fois un encodeur utilisé.

5.4 N3 : tête d'attention sur 16 tranches de temps

En N2, tout l'extrait est résumé par une moyenne. En N3, on garde **16 tranches de temps** de même durée, et un petit réseau apprend lesquelles comptent le plus (par exemple un cri au milieu d'une scène).

Pour chaque tranche, l'entrée est le vecteur de l'encodeur gelé, moyenné sur toutes ses couches et sur la durée de la tranche (1 280 valeurs pour Whisper). La tête comporte trois couches apprises :

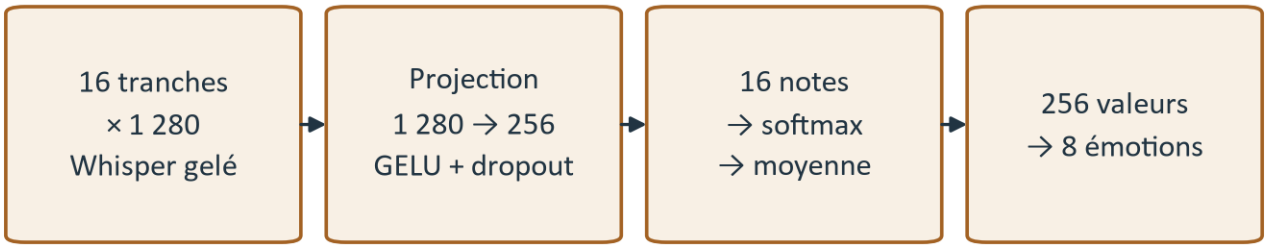


Figure 13 · Tête d'attention du N3. La même couche cachée transforme chaque tranche ; un neurone donne une note d'importance à chaque tranche ; la moyenne pondérée par ces notes résume l'extrait ; la couche de sortie donne les 8 émotions.

1. une **couche cachée**, la même pour les 16 tranches : 1 280 256 neurones, activation GELU (transformation non linéaire), dropout (mise à zéro aléatoire de neurones pendant l'apprentissage) ;
2. un **neurone de score** (256 1) qui note l'importance de chaque tranche ; un *softmax* transforme les 16 notes en 16 poids qui font 100 % ;
3. après la **moyenne pondérée** des 16 vecteurs de 256 valeurs, une **couche de sortie** de 8 neurones (256 8), une par émotion.

```
pour chaque tranche t : z(t) = dropout(GELU(W1 · x(t) + b1)) (256 valeurs)
s(t) = w2 · z(t) + b2 (une note)
poids : a(t) = exp(s(t)) / somme des exp(s) (16 poids, total 1)
résumé : h = somme sur t de a(t) × z(t) (256 valeurs)
sortie : p = softmax(W3 · dropout(h) + b3) (8 probabilités)
```

Cela représente environ **330 000 paramètres** pour Whisper (1 280 × 256 + 256, plus 257, plus 256 × 8 + 8), contre environ 10 000 pour la régression logistique du N2. **Apprentissage** : entropie croisée pondérée par classe, optimiseur AdamW (algorithme de mise à jour des poids), lots de 64 extraits, nombre d'époques fixé (une époque est un passage sur les données ; pas d'arrêt précoce, pour ne pas utiliser le pli de validation pendant l'apprentissage). À chaque lot, une partie des tranches est retirée au hasard, pour que le réseau ne dépende pas d'un seul moment. **Réglages** : 30 essais Optuna, chacun évalué en validation croisée, sur la taille de la couche cachée (128, 256 ou 512), le dropout (0,1 à 0,6), le taux d'apprentissage (1e-4 à 3e-3), la régularisation des poids (1e-4 à 0,1), le nombre d'époques (5 à 40) et la part de tranches retirées (0 à 50 %). Le réglage retenu est ensuite réappris avec 3 graines aléatoires, dont on moyenne les probabilités. Pour Whisper : 256 neurones, dropout 0,54, taux d'apprentissage 1,2e-4, 31 époques, 20 % des tranches retirées.

Tableau 12 · N2 contre N3 pour chaque encodeur (F1 cv : moyenne des cinq plis)

Encodeur	N2 (F1 cv)	N3 attention (F1 cv)	N3 (F1 dev)
Whisper	**0,265**	0,258	0,268
WavLM	0,256	**0,258**	0,255
wav2vec2 émotion	**0,249**	0,242	0,265
AST	**0,241**	0,235	0,243

L'attention ne bat pas la simple moyenne : les extraits sont courts (6,5 s en médiane, donc des tranches d'environ 0,4 s), il y a peu de moments à « choisir », et 2 207 exemples suffisent mal à apprendre 30 fois plus de

paramètres qu'en N2. Mais les têtes d'attention ne se trompent pas sur les mêmes extraits que les régressions logistiques : elles sont utiles à la combinaison.

5.5 Système audio final : combinaison de quatre modèles

Les 11 sorties audio (N1, six en N2, quatre en N3) sont classées par F1 cv, puis on fait la moyenne des probabilités des k meilleures (partie 4.7).

Tableau 13 · F1 cv de la moyenne des k meilleurs modèles audio

k	1	2	3	4	6	8	11
F1 cv	0,269	0,269	0,268	**0,271**	0,266	0,268	0,261

Le système audio final est la **moyenne des probabilités de quatre modèles** : Whisper en N2 (couche 16 + régression logistique), Whisper en N3 (attention), WavLM en N2 et WavLM en N3. Pour chaque extrait, l'émotion retenue est celle de plus forte probabilité moyenne. **F1 cv 0,271, F1 dev 0,270**, exactitude dev 28,5 %. Le gain sur Whisper seul n'est pas significatif (intervalle de confiance par films [−0,022 ; +0,028]) ; la combinaison stabilise surtout le résultat.

Une première version de l'audio (AST + N1 + SVM) affichait 0,269 sur dev, mais avec des réglages choisis sur dev et sans prédictions hors pli. Elle a été refaite avec le protocole commun : le score est équivalent, mais il est mesuré honnêtement et utilisable pour la fusion.

5.6 Matrices de confusion de l'audio

Les scores inscrits dans les matrices utilisent les prédictions hors pli regroupées : Whisper N2 donne 0,269 et Whisper N3 0,264. Les tableaux de recherche donnent la moyenne des cinq plis (0,265 et 0,258). Ce sont deux calculs du F1, définis au chapitre 4, sur les mêmes sorties. Abréviations communes : amu (amusement), ang (colère), awe (émerveillement), con (satisfaction), dis (dégoût), exc (excitation), fea (peur), sad (tristesse).

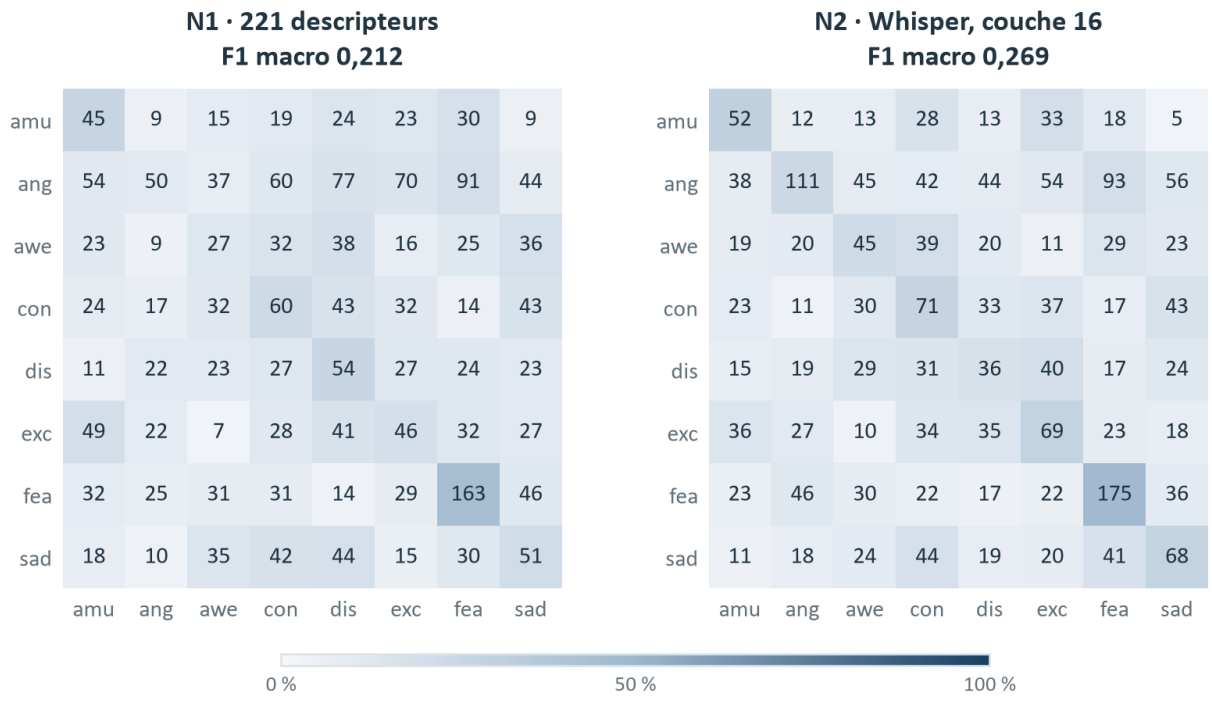


Figure 14 · Validation croisée · N1 et N2. Lignes : émotion réelle ; colonnes : prédiction. Cases : effectifs ; couleur : part par ligne.

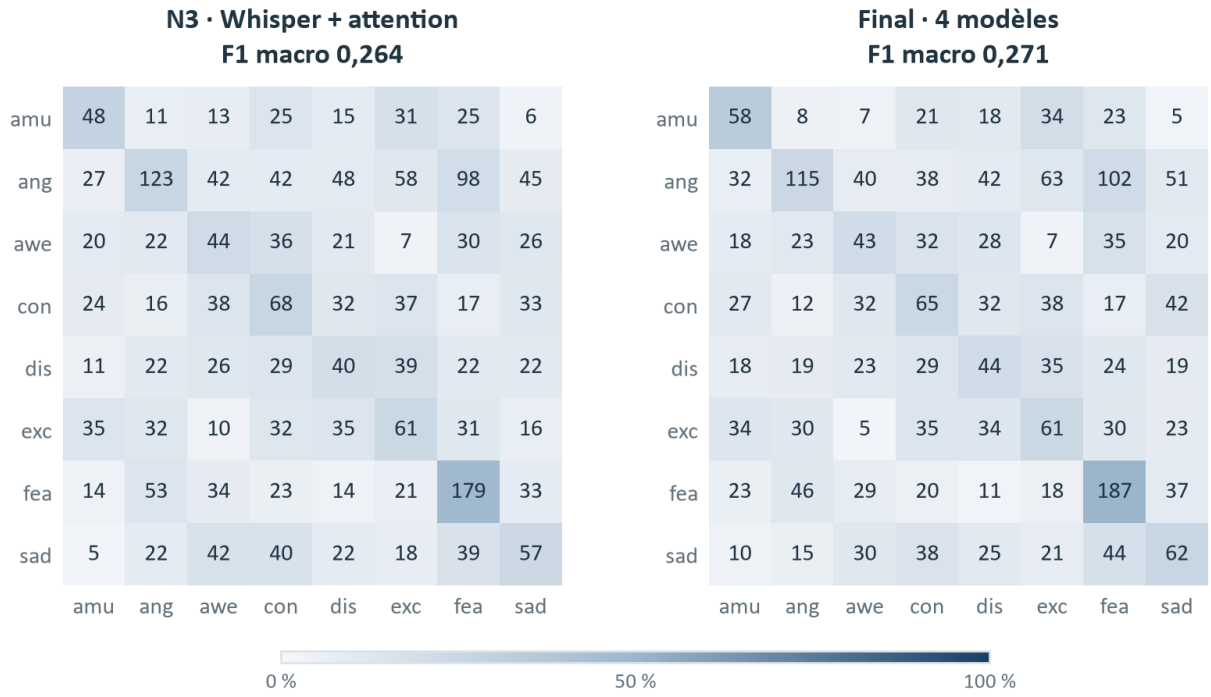


Figure 15 · Validation croisée · N3 et système final. Même échelle de 0 à 100 %.

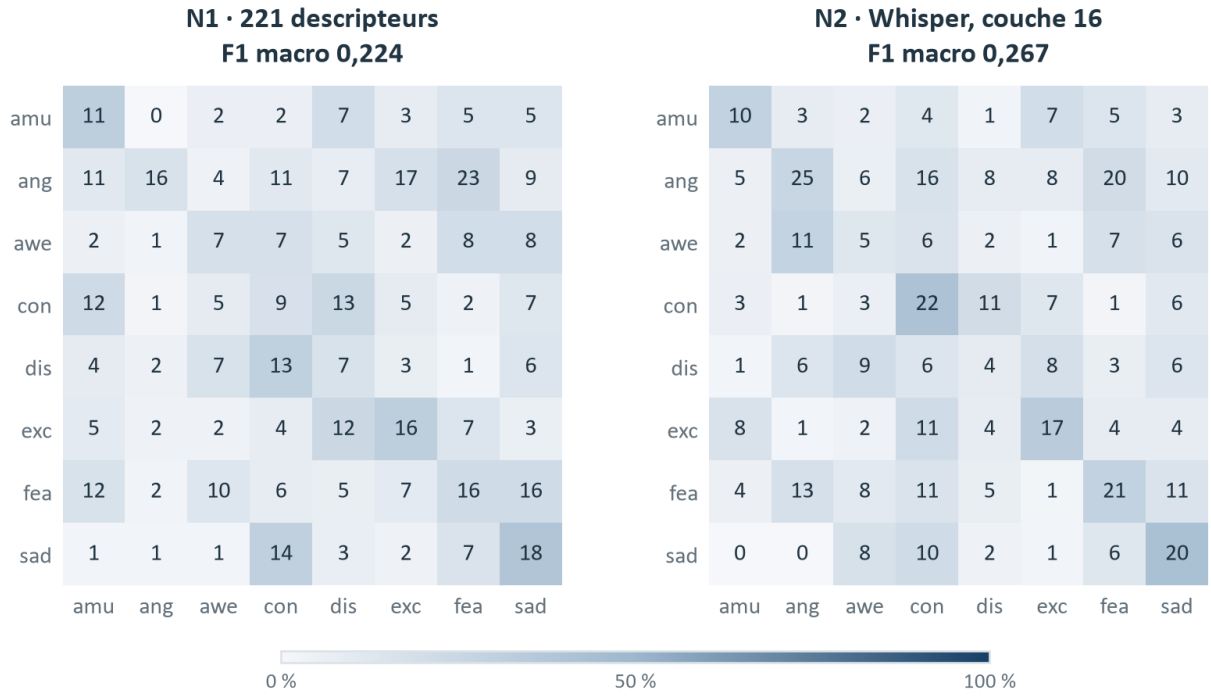


Figure 16 · Développement · N1 et N2. Lignes : émotion réelle ; colonnes : prédiction. Cases : effectifs ; couleur : part par ligne.

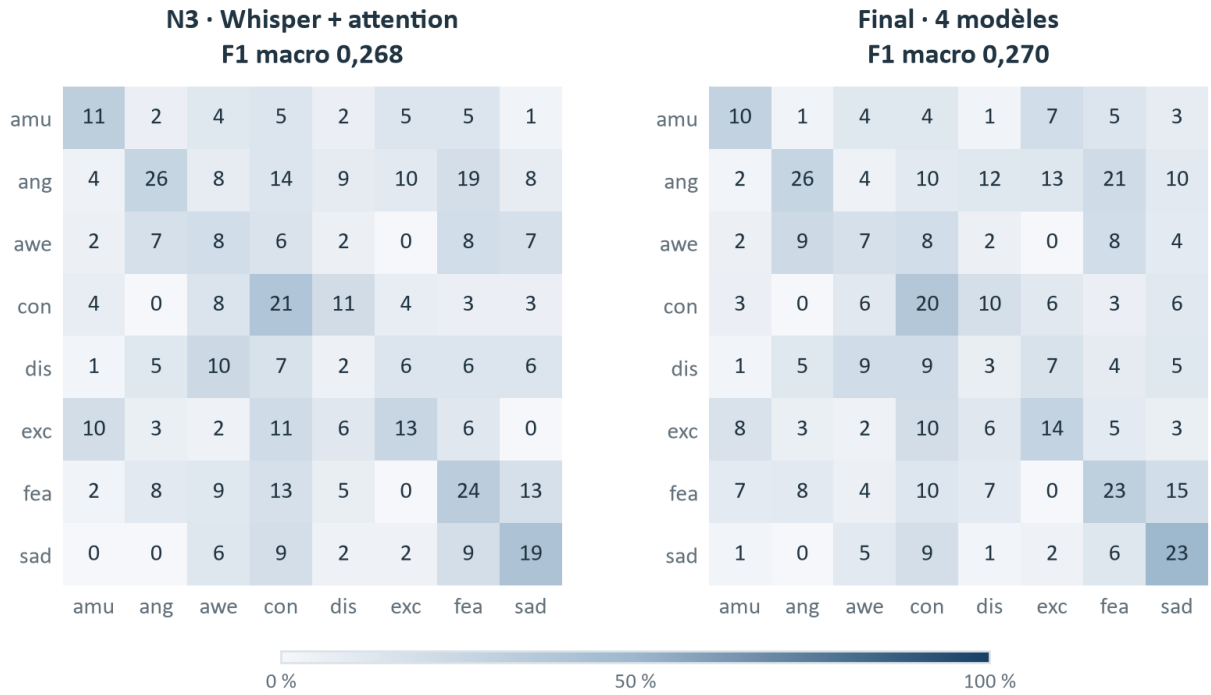


Figure 17 · Développement · N3 et système final. Même échelle de 0 à 100 %.

Comment les lire : chaque ligne correspond à une émotion réelle, chaque colonne à l'émotion prédite. La diagonale contient les bonnes réponses. Par exemple, en validation croisée, le système final reconnaît 187 extraits de peur sur 371, mais en prend 102 de colère pour de la peur. Les matrices montrent que l'audio reconnaît le mieux **la peur et la tristesse** (cris, musique angoissante ou mélancolique) et qu'il confond souvent **la colère avec la peur** : deux émotions « fortes » qui se ressemblent à l'oreille. Le **dégoût** et l'**émerveillement** sont presque invisibles dans le son. Le passage de N1 à N2 se voit nettement sur la diagonale, puis la combinaison renforce surtout la peur et la tristesse.

À RETENIR

Whisper et WavLM, chacun avec régression logistique et attention, forment le système final. L'intensité et le timbre contribuent davantage que la hauteur vocale. L'audio capte surtout la peur et la tristesse.

6. Modèle texte (point 4)

EN BREF

Description et dialogue sont étudiés séparément puis ensemble. Le TF-IDF sert de référence ; les encodeurs apportent le contexte des mots. Le fine-tuning ajuste ensuite l'encodeur à la tâche. Six modèles combinés atteignent 0,362 en F1 cv et 0,387 sur dev.

6.1 Entrée

L'entrée est la **description** de la scène (fournie avec le corpus) et le **dialogue** transcrit au point 3. La description fait 53 mots en moyenne, le dialogue 16 ; un tiers des extraits n'a pas de dialogue, et seulement 41 % des extraits de peur en ont un. La description décrit surtout ce que l'on voit : elle porte donc, elle aussi, une information visuelle.

6.2 N1 : TF-IDF et régression logistique

Le **TF-IDF** (*term frequency – inverse document frequency*) représente un texte par les mots qu'il contient, chacun avec un poids :



Figure 18 · N1 texte : le texte devient une liste pondérée de mots et de paires de mots, puis une régression logistique apprend un poids par mot et par émotion.

- **TF** : plus un mot est fréquent **dans ce texte**, plus il pèse (en logarithme, pour qu'un mot répété dix fois ne pèse pas dix fois plus) ;
- **IDF** : plus un mot est **rare dans l'ensemble des textes**, plus il pèse. « the » ou « man » apparaissent partout et pèsent peu ; « screams » ou « funeral » sont rares et pèsent beaucoup.

Réglages : mots seuls et **paires de mots** (bigrammes, par exemple « dark room »), mots vides anglais retirés (*the*, *a*, *is*…), mots présents dans au moins deux textes. Le vocabulaire obtenu sur train compte **8 167 mots et paires** : chaque texte devient un vecteur de 8 167 valeurs, presque toutes nulles. Une **régression logistique** apprend ensuite un poids par mot et par émotion, exactement comme pour les descripteurs audio (partie 5.2). Le vocabulaire et les poids IDF sont réappris dans chaque pli de la validation croisée, puisqu'ils dépendent des textes d'apprentissage. Le réglage C est choisi parmi 0,1 ; 0,3 ; 1 ; 3 et 10, avec ou sans pondération des classes ; un SVM linéaire est aussi comparé.

Tableau 14 · N1 texte (F1 cv : moyenne des cinq plis)

Entrée	Régression logistique	SVM linéaire
description	0,286	0,282
dialogue	0,158	0,154
description + dialogue	**0,295**	0,287

Réglage retenu : description et dialogue réunis en un seul texte, régression logistique, C = 1, classes pondérées (**F1 cv 0,295, dev 0,295**). La régression logistique est gardée même quand le SVM fait jeu égal, parce qu'elle donne des probabilités, nécessaires aux combinaisons et à la fusion.

Comme pour l'audio, on peut lire ce que le modèle a appris : les mots qui ont le plus fort poids positif pour chaque émotion.

Tableau 15 · Mots et paires de mots les plus associés à chaque émotion (N1 texte, modèle appris sur train)

Émotion	Mots les plus associés
amusement	dancing, playing, smiling, lively, lively scene, cows, ice
anger	gun, man, plaid, plaid shirt, men, uniform, hair beard
awe	man suit, suit, tie, bus, flashlight, robes, desert
contentment	lying bed, sitting, trees, child, lying, bed, woman sitting
disgust	subway, subway car, woman blonde, shirt, car, table, standing room
excitement	smiling, smiling looking, sunglasses, engaged conversation, jacket, boat, hats
fear	dark, person, dark room, lying, large, ground, light
sadness	dark, background dark, dimly, dimly lit, lit room, kitchen, lit

Le modèle s'appuie surtout sur la **description visuelle** : l'obscurité (*dark*, *dimly lit*) annonce la peur et la tristesse, les sourires et la danse l'amusement et l'excitation, les armes la colère. Certains mots reflètent des habitudes du corpus plus que l'émotion (*plaid shirt*, *subway*), signe que le modèle apprend aussi des particularités de quelques films : c'est pour cette raison que la validation croisée est groupée par film.

6.3 N2 : encodeurs de phrases pré-entraînés et gelés

Un encodeur de phrases est un réseau Transformer pré-entraîné à rapprocher les phrases de même sens. Le texte est découpé en **jetons** (des morceaux de mots), chaque couche transforme les vecteurs des jetons, et la **moyenne des vecteurs de la dernière couche** donne un vecteur pour tout le texte. L'encodeur est gelé ; seule une régression logistique est apprise (C entre 0,0003 et 0,03, avec ou sans pondération des classes).

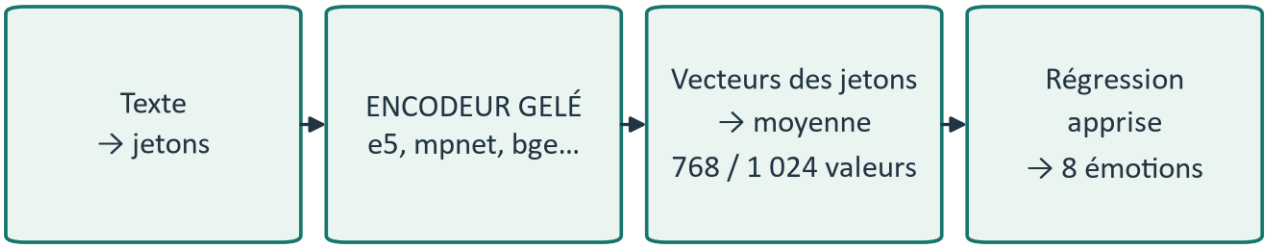


Figure 19 · N2 texte : un encodeur de phrases gelé transforme le texte en un vecteur ; seule la régression logistique est apprise.

Tableau 16 · Les cinq encodeurs de phrases du N2 texte

Nom	Modèle	Couches	Taille du vecteur	Particularité
mpnet	sentence-transformers/all-mpnet-base-v2	12	768	encodeur de phrases généraliste
e5	intfloat/e5-large-v2	24	1 024	encodeur généraliste ; le texte est préfixé par « query: », comme le demande le modèle
bge	BAAI/bge-large-en-v1.5	24	1 024	encodeur généraliste
goemotions	SamLowe/roberta-base-go_emotions	12	768	déjà entraîné à reconnaître 28 émotions (commentaires Reddit)
ekman	j-hartmann/emotion-english-roberta-large	24	1 024	déjà entraîné sur les 6 émotions d'Ekman et le neutre

Quatre façons de donner le texte sont comparées : la description seule, le dialogue seul, les deux encodés **séparément** puis mis bout à bout (le vecteur du dialogue vaut 0 s'il n'y en a pas, avec un indicateur « dialogue présent »), ou les deux **concaténés** en un seul texte.

Tableau 17 · N2 texte (F1 cv ; en gras, l'entrée retenue pour chaque modèle)

Modèle	description	dialogue	description + dialogue	concaténation
e5	0,323	0,175	0,324	**0,330**
ekman	0,319	0,172	**0,321**	0,313
mpnet	0,314	0,169	**0,320**	0,308
bge	0,313	0,176	**0,315**	0,313
goemotions	**0,299**	0,169	0,295	0,288

- Les encodeurs pré-entraînés dépassent le TF-IDF (jusqu'à +3,5 points pour e5) : ils connaissent les synonymes et le contexte, alors que le TF-IDF doit tout apprendre de 2 207 extraits.
- Le **dialogue seul est faible** ($F_1 \approx 0{,}17$) ; ajouté à la description, il aide un peu.
- La moyenne des six modèles N1 et N2 donne 0,352 en CV et 0,366 sur dev.

6.4 N3 : fine-tuning

Au N3 du texte, le modèle n'est plus gelé : il est **affiné** sur nos données. Différence essentielle avec le N2 : en N2, seuls les poids de la régression logistique sont appris (de 8 000 à 16 000 environ) ; ici, **toutes les couches** (110 à 355 millions de paramètres) sont ajustées pour notre tâche. Le déroulé :

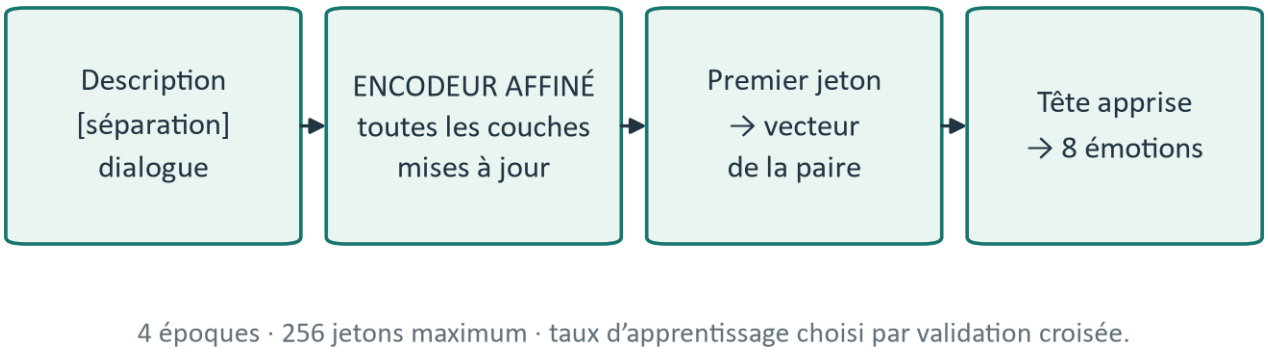


Figure 20 · Fine-tuning du texte : toutes les couches de l'encodeur sont mises à jour, avec une nouvelle tête de classification à 8 émotions.

1. description et dialogue sont donnés comme une **paire de textes** (« [début] description [séparation] dialogue »), coupée à 256 jetons ;
2. une **nouvelle tête de classification** à 8 sorties est posée sur le vecteur du premier jeton, qui résume la paire ;
3. l'apprentissage minimise l'entropie croisée **pondérée par classe**, avec AdamW (régularisation 0,01), 4 époques, des lots de 16 textes, en demi-précision sur la carte graphique ; le taux d'apprentissage monte pendant les premiers 10 % des étapes, puis décroît linéairement jusqu'à zéro ;
4. le **taux d'apprentissage** est choisi parmi 1e-5, 2e-5 et 3e-5 : pour chaque taux, une validation croisée complète (5 modèles affinés) ; le meilleur taux sert au modèle final, affiné sur tout train.

Les cinq modèles du N2 et RoBERTa-large sont affinés : 6 modèles × 3 taux × 5 plis, plus les modèles finaux, soit environ 3 h 30 de calcul.

Tableau 18 · N3 texte (F1 cv par taux d'apprentissage ; en gras, le taux retenu)

Modèle	lr 1e-5	lr 2e-5	lr 3e-5	Gelé (N2)	F1 dev
ekman (RoBERTa-large, émotions)	0,320	0,335	**0,341**	0,322	0,352
e5-large	0,315	0,318	**0,335**	0,330	0,339
RoBERTa-large	**0,331**	0,310	0,270	—	0,368
bge-large	0,318	**0,323**	0,313	0,315	0,370
goemotions (RoBERTa-base)	0,260	0,292	**0,297**	0,299	0,323
mpnet (base)	0,278	**0,290**	0,288	0,320	0,292

- Le fine-tuning aide les **grands** modèles (ekman +1,9 point, bge +0,8, e5 +0,5 en CV) mais pas les **petits** : mpnet perd 3 points, signe de surapprentissage avec 2 207 exemples.
- Le taux d'apprentissage compte beaucoup : RoBERTa-large passe de 0,331 à 0,270 entre 1e-5 et 3e-5 ; un taux fixe aurait faussé la comparaison.
- Un pré-entraînement sur des émotions semble aider : ekman dépasse RoBERTa-large d'un point en CV.

6.5 Système texte final et matrices de confusion

La combinaison (partie 4.7) retient **6 modèles** : ekman, e5, RoBERTa et bge affinés, plus e5 et ekman gelés. **F1 cv 0,362, F1 dev 0,387**, exactitude 38,9 %. Le gain sur le meilleur modèle seul est significatif sur dev (intervalle [+0,003 ; +0,066]) : la combinaison progresse surtout parce que les modèles affinés se trompent sur des extraits différents. En n'affinant qu'ekman, elle restait à 0,351 en CV.

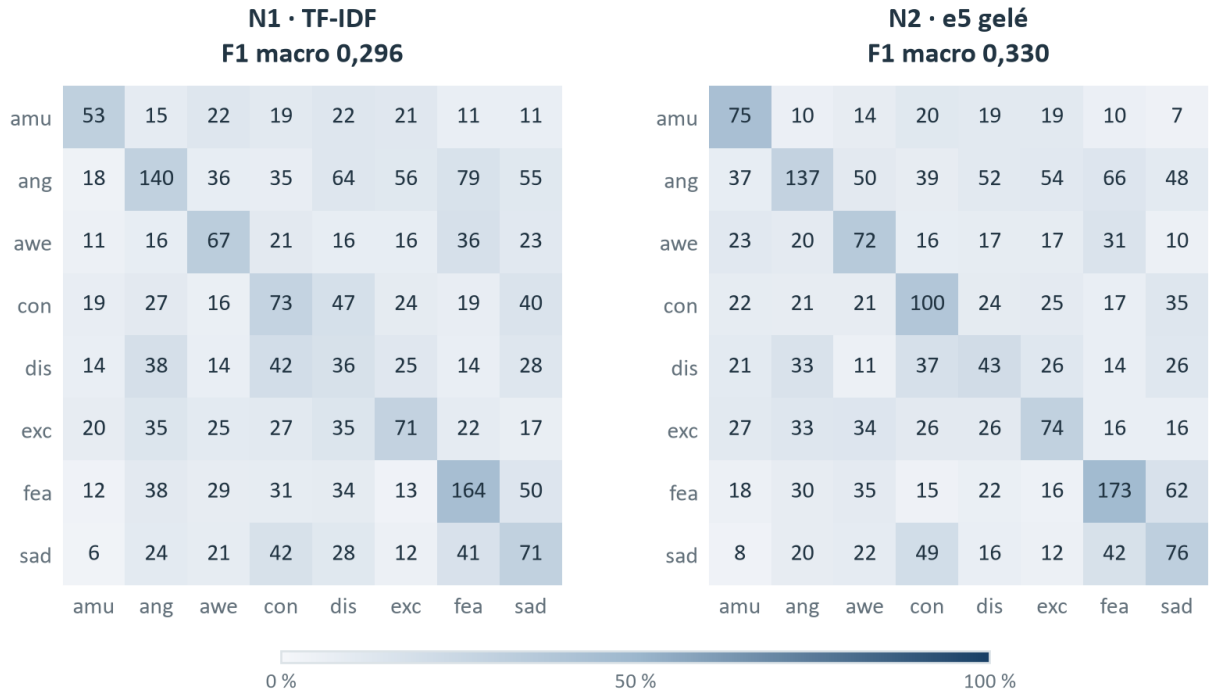


Figure 21 · Validation croisée · N1 et N2. Lignes : émotion réelle ; colonnes : prédiction. Cases : effectifs ; couleur : part par ligne.

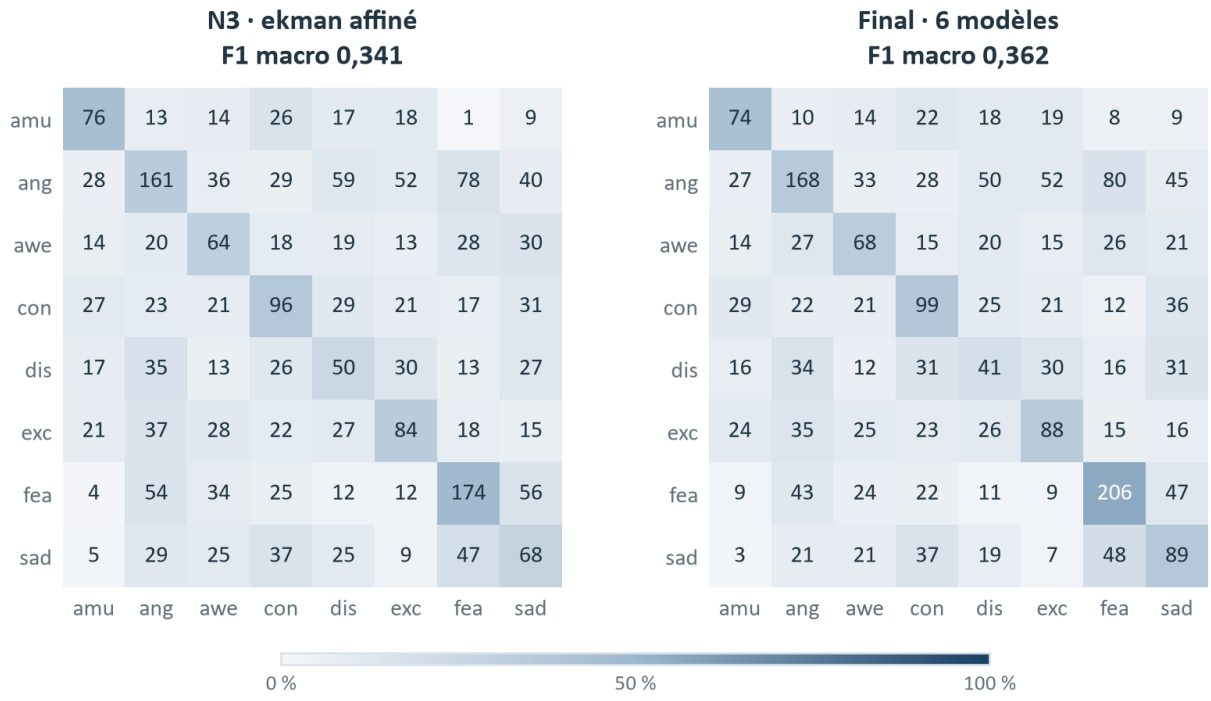


Figure 22 · Validation croisée · N3 et système final. Même échelle de 0 à 100 %.

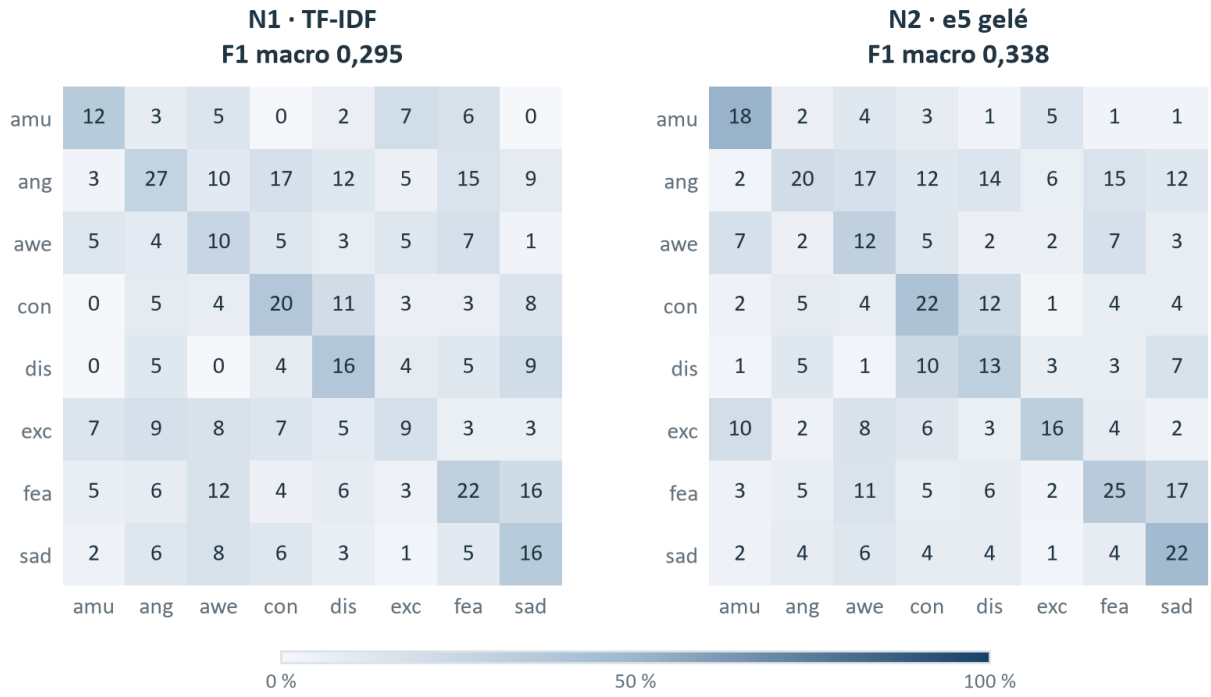


Figure 23 · Développement · N1 et N2. Lignes : émotion réelle ; colonnes : prédiction. Cases : effectifs ; couleur : part par ligne.

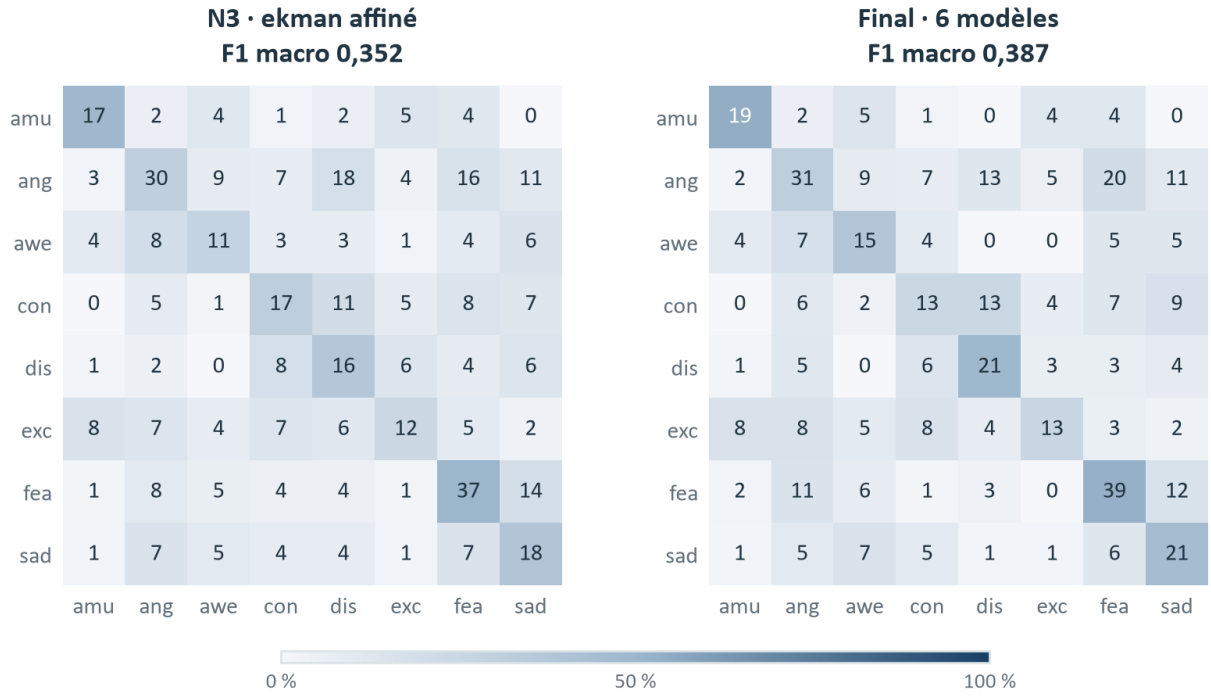


Figure 24 · Développement · N3 et système final. Même échelle de 0 à 100 %.

Le texte reconnaît bien l'**amusement** et la **peur**, et c'est la meilleure modalité pour le **dégoût** (F1 dev 0,43, contre 0,27 pour la vidéo) : le dégoût se dit ou se décrit plus qu'il ne se voit. Les confusions les plus fréquentes concernent les trois émotions positives proches, *awe*, *excitement* et *contentment* : la description dit ce qui se passe, rarement ce que l'on ressent.

À RETENIR

La description apporte l'essentiel du signal ; le dialogue seul reste faible. L'affinage aide surtout les grands modèles. Le texte complète particulièrement bien la vidéo pour le dégoût.

7. Modèle vidéo (point 4)

EN BREF

Seize images résument chaque extrait. Les descripteurs de couleur sont comparés aux encodeurs d'images et aux expressions faciales. Une attention peut pondérer les images. Six modèles combinés atteignent 0,450 en F1 cv et 0,461 sur dev.

7.1 Préparation des images

Écrans de fin. Le nettoyage décrit au chapitre 2 fixe la fin utile des 33 extraits concernés, sans utiliser leurs étiquettes.

Seize images par extrait (01_extraire_images.py) : la partie utile est découpée en 16 intervalles égaux, et l'on prend l'image au milieu de chacun. On évite ainsi la toute première et la toute dernière image, souvent un fondu ou un changement de plan. Les images sont gardées en couleur, sans recadrage, avec 640 pixels de large au plus (assez pour détecter les visages).

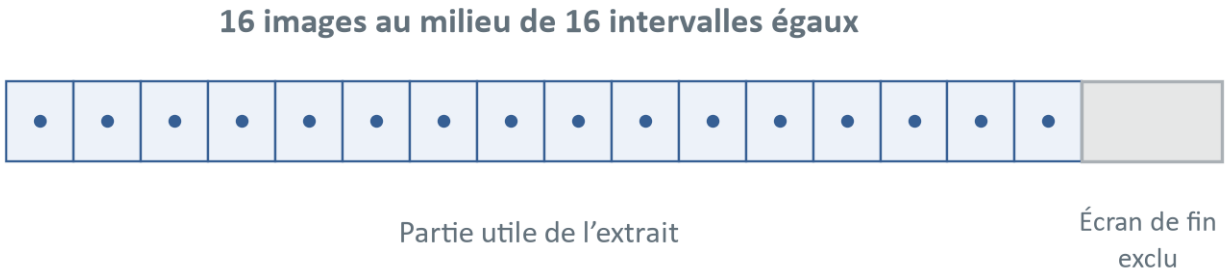


Figure 25 · Extraction des images : 16 images par extrait, prises au milieu de 16 intervalles égaux de la partie utile.

7.2 N1 : couleurs, luminosité et mouvement

Chaque image est réduite à 160 × 90 pixels et convertie en **HSV** : teinte (la couleur), saturation (couleur vive ou grisée) et luminosité. Sur chaque image, on calcule :

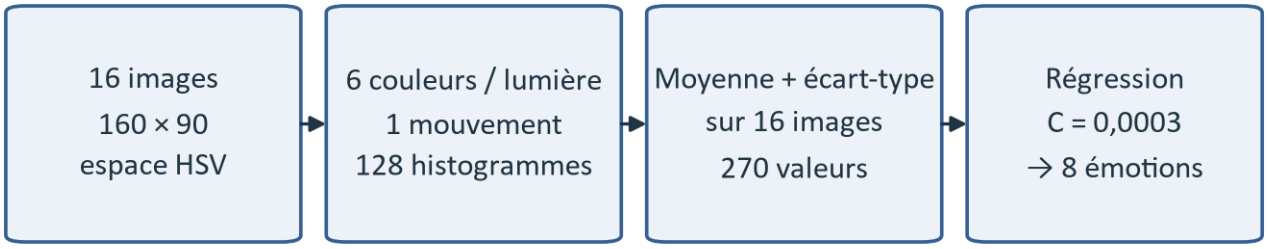


Figure 26 · N1 vidéo : descripteurs de couleur, de luminosité et de mouvement, résumés sur les 16 images.

- la moyenne et l'écart-type de la teinte, de la saturation et de la luminosité (6 valeurs) ;
- le **mouvement** : la différence moyenne de luminosité avec l'image précédente (1 valeur) ;
- un **histogramme de couleurs** : la part des pixels dans chacune des 8 teintes × 4 saturations × 4 luminosités (128 valeurs).

Ces 135 valeurs sont résumées sur les 16 images par leur moyenne et leur écart-type : **270 descripteurs**. Régression logistique, C choisi parmi 9 valeurs de 0,0001 à 1 : retenu **C = 0,0003** (régularisation très forte), classes pondérées. **F1 cv 0,192, F1 dev 0,200.**

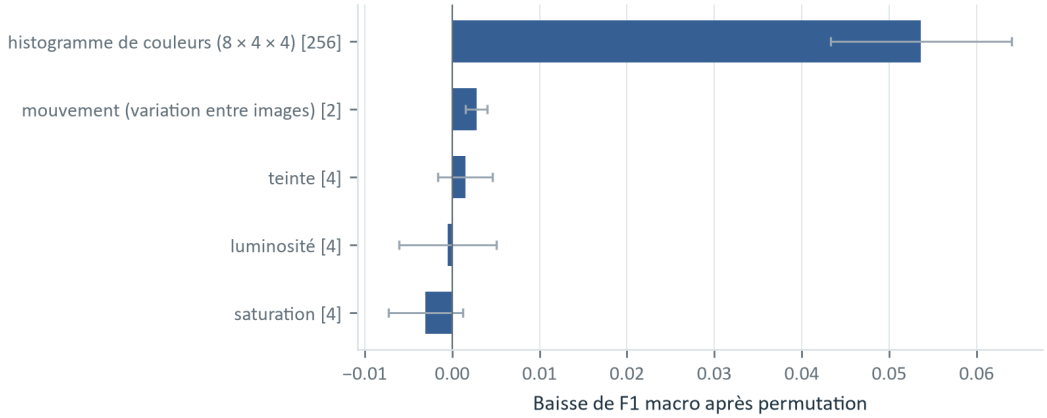


Figure 27 · Importance des familles de descripteurs du N1 vidéo : baisse du F1 macro quand la famille est brouillée, en moyenne sur les 5 plis.

Mesurée comme pour l'audio (permutation par famille en validation croisée), l'importance montre que l'**histogramme de couleurs** porte presque toute l'information : le brouiller fait perdre 0,054 de F1, soit près de 30 % du score. La teinte, la saturation et la luminosité moyennes n'apportent rien de plus, car l'histogramme les contient déjà ; le mouvement apporte un peu. Les couleurs décrivent l'**ambiance** d'une scène (sombre, chaude, froide), mais peu son contenu émotionnel : d'où un score modeste. Ce recalcul redonne exactement le score du module (0,185 en moyenne par pli), ce qui vérifie que le N1 se reproduit.

7.3 N2 : encodeurs d'images gelés et visages

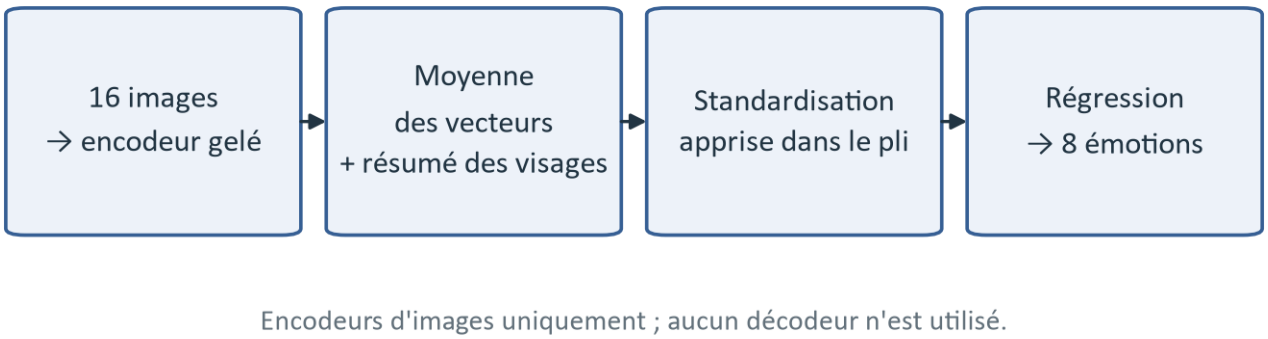


Figure 28 · N2 vidéo : un encodeur d'images gelé donne un vecteur par image ; les 16 vecteurs sont moyennés et complétés par un résumé des visages ; seule la régression logistique est apprise.

Les encodeurs d'images

Tableau 19 · Les sept encodeurs vidéo comparés en N2

Encodeur	Modèle	Pré-entraînement	Vecteur
CLIP-B	openai/clip-vit-base-patch16	paires image-texte (OpenAI, 2021)	512 par image
CLIP-L	openai/clip-vit-large-patch14	idem, modèle plus grand	768 par image
CLIP-H	laion/CLIP-ViT-H-14-laion2B-s32B-b79K	2 milliards de paires image-texte (LAION)	1 024 par image
SigLIP 2	google/siglip2-so400m-patch14-384	paires image-texte (Google, 2025)	1 152 par image
PE	timm/PE-Core-L-14-336 (*Perception Encoder*)	paires image-texte (Meta, 2025)	1 024 par image
DINOv2	facebook/dinov2-base	images seules, auto-supervisé	768 par image
VideoMAE	MCG-NJU/videomae-base-finetuned-kinetics	les 16 images ensemble (actions, Kinetics-400)	768 par extrait

Les modèles **image-texte** (CLIP, SigLIP 2, PE) ont appris à rapprocher une image de sa légende : leurs vecteurs résument des **concepts** (une pièce sombre, une arme, un enfant qui rit, un visage crispé), ce qui les rend très adaptés à notre tâche. Comme pour l'audio, on n'utilise que leur **encodeur d'images** (pas leur partie texte) : chaque image donne un vecteur, normalisé à une longueur de 1. DINOv2 ne connaît que les images ; VideoMAE regarde les 16 images ensemble pour capter le mouvement et donne un seul vecteur par extrait.

Les visages

Sur chacune des 16 images, **YuNet** (détecteur de visages d'OpenCV) cherche les visages (score de confiance d'au moins 0,6) et l'on garde les deux plus grands. Chaque visage est découpé avec une marge de 20 % puis décrit par deux modèles d'**expression faciale** gelés :

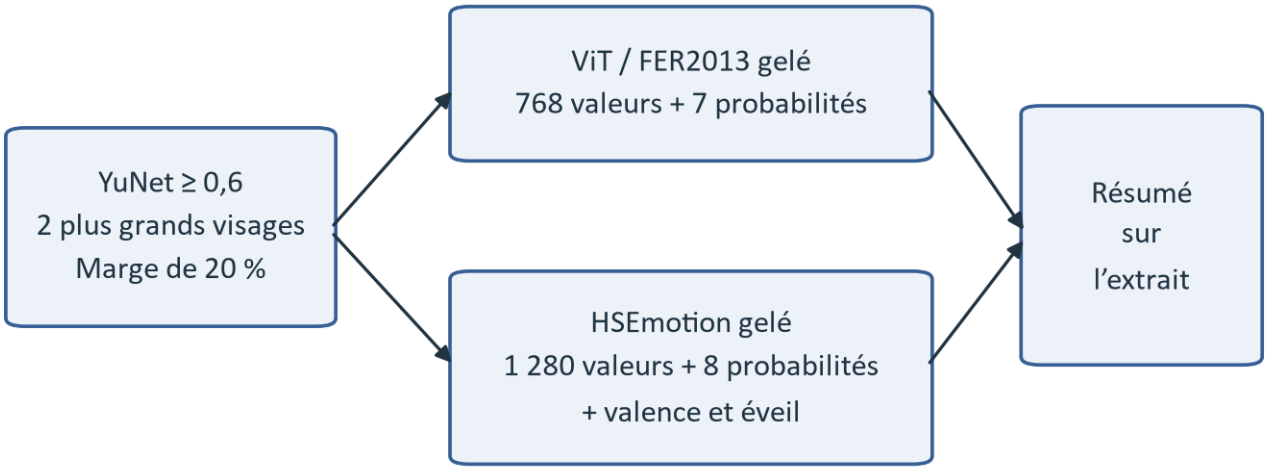


Figure 29 · Traitement des visages : détection, découpe, puis deux modèles d'expression faciale gelés ; leurs sorties sont résumées sur l'extrait.

- un **ViT entraîné sur FER2013** : un vecteur de 768 valeurs et 7 probabilités d'expression (colère, dégoût, peur, joie, tristesse, surprise, neutre) ;
- **HSEmotion** (EfficientNet-B0 entraîné sur AffectNet, des photos réelles) : un vecteur de 1 280 valeurs, 8 probabilités d'expression, plus la **valence** (agréable ou désagréable) et l'**éveil** (calme ou excité).

Pour le N2, ces sorties sont **résumées sur l'extrait** : part des images avec un visage, nombre moyen de visages, taille moyenne du plus grand visage, présence d'au moins un visage, puis, pour chaque modèle, la moyenne de ses vecteurs et de ses probabilités sur tous les visages trouvés, le maximum de chaque probabilité,

et la valence et l'éveil moyens. Les expressions faciales ne sont pas nos huit émotions : le classifieur apprend lui-même leur lien avec elles.

Tableau 20 · Part des images contenant au moins un visage, par émotion

amusement	anger	awe	contentment	disgust	excitement	fear	sadness
77 %	87 %	69 %	81 %	90 %	86 %	**52 %**	80 %

Au moins un visage est détecté dans 2 849 extraits sur 3 088. La **peur** se distingue : seulement 52 % de ses images contiennent un visage (scènes sombres, menace hors champ, plans larges), contre 90 % pour le dégoût. L'absence de visage est donc elle-même une information utile.

La recherche des réglages

Comme pour l'audio, on avance étape par étape pour chaque encodeur, en gardant à chaque étape le meilleur F1 cv : nombre d'images (4, 8 ou 16) et résumé (moyenne, ou moyenne + écart-type), puis visages (aucun, ViT, HSEmotion ou les deux), puis classifieur (régression logistique avec C entre 0,00001 et 0,1, analyse discriminante, ou SVM réglé par 25 essais Optuna puis calibré) ; enfin, les visages seuls. **123 configurations** au total ; la régression logistique est retenue pour toutes les sorties.

Tableau 21 · Meilleure configuration de chaque encodeur vidéo (F1 cv sur les prédictions hors pli)

Sortie retenue	Images	Visages	F1 cv	F1 dev
PE	16	ViT + HSEmotion	**0,430**	**0,441**
SigLIP 2	16	ViT	0,408	0,415
CLIP-B	8	ViT	0,406	0,417
CLIP-H	16	HSEmotion	0,405	0,417
CLIP-L	16	ViT	0,401	0,423
DINOv2	4	HSEmotion	0,373	0,399
VideoMAE	16 (un vecteur par extrait)	ViT + HSEmotion	0,358	0,404
Visages seuls	—	ViT	0,304	0,321

- Les modèles **image-texte récents** (PE, SigLIP 2) sont les meilleurs ; DINOv2 (images seules) et VideoMAE (mouvement) sont derrière : nos émotions se lisent plus dans le **contenu** des images que dans le mouvement.
- La **moyenne simple** des 16 vecteurs suffit ; l'écart-type n'aide pas.
- Les **visages seuls** font 0,304, mais ajoutés aux images ils aident **toutes** les configurations retenues : ils apportent l'expression, que l'encodeur général capte moins bien.

7.4 N3 : tête d'attention sur les 16 images

C'est la **même tête d'attention** que pour l'audio (partie 5.4, figure de la tête d'attention), les 16 tranches de son étant remplacées par les 16 images : une couche cachée commune, un neurone de score par image, une moyenne pondérée, une couche de sortie. L'entrée de chaque image est le vecteur de l'encodeur, auquel on ajoute les caractéristiques du **plus grand visage de cette image** : présence, taille, vecteur et probabilités du modèle d'expression choisi (0 s'il n'y a pas de visage). Le choix des visages (aucun, ViT, HSEmotion, les deux) fait partie des réglages d'Optuna, avec la taille de la couche cachée, le dropout, le taux d'apprentissage, la régularisation, le nombre d'époques et la part d'images retirées au hasard pendant l'apprentissage. Réglage retenu pour PE : visages ViT, 128 neurones, dropout 0,53, taux d'apprentissage 3e-4, 17 époques, 26 % des images retirées.

Tableau 22 · N2 contre N3 pour les encodeurs vidéo (F1 cv)

Encodeur	N2	N3 attention	F1 dev de N3
PE	**0,430**	0,421	0,454
SigLIP 2	0,408	**0,419**	0,428
CLIP-L	0,401	0,401	0,422
CLIP-H	**0,405**	0,395	0,444
CLIP-B	**0,406**	0,393	0,380
DINOv2	**0,373**	0,369	0,395

Comme pour l'audio, l'attention n'améliore pas systématiquement le modèle seul (SigLIP 2 progresse, PE recule), mais ses erreurs sont différentes et elle sert la combinaison.

7.5 Système vidéo final et matrices de confusion

La combinaison retient **6 modèles** : PE, SigLIP 2, CLIP-B et CLIP-H avec régression logistique, plus PE et SigLIP 2 avec attention. **F1 cv 0,450, F1 dev 0,461**, exactitude 45,7 %. Le gain sur PE seul n'est pas significatif sur dev (intervalle [−0,008 ; +0,047]).

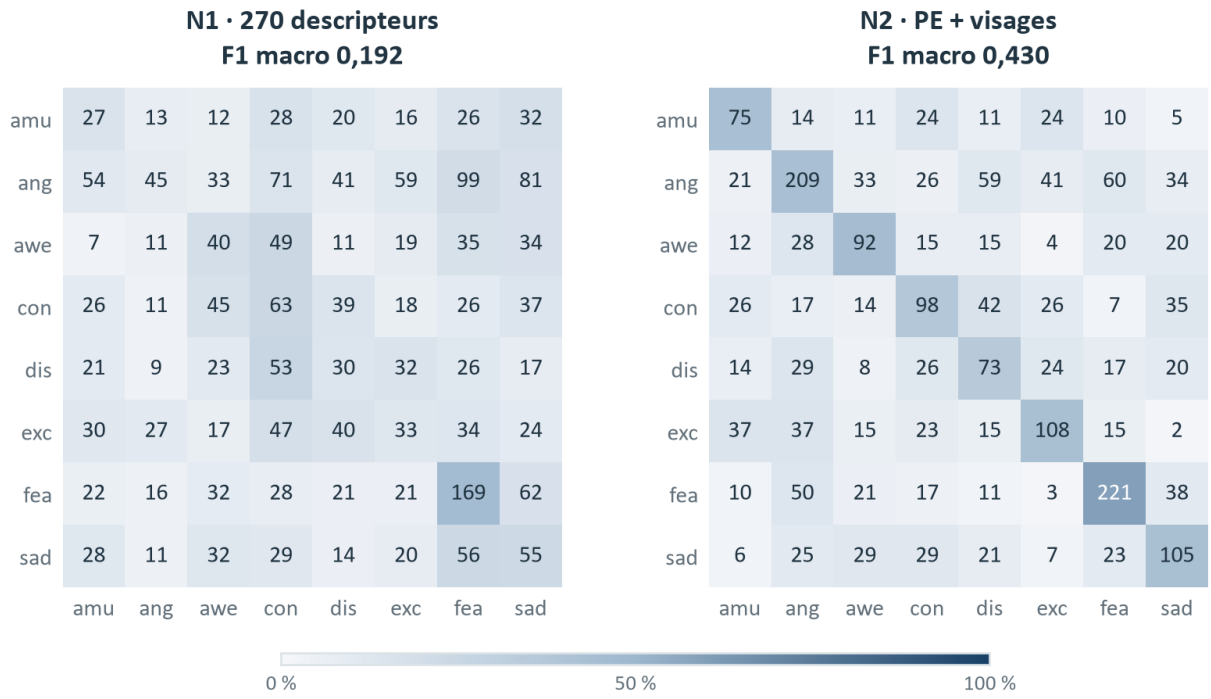


Figure 30 · Validation croisée · N1 et N2. Lignes : émotion réelle ; colonnes : prédiction. Cases : effectifs ; couleur : part par ligne.

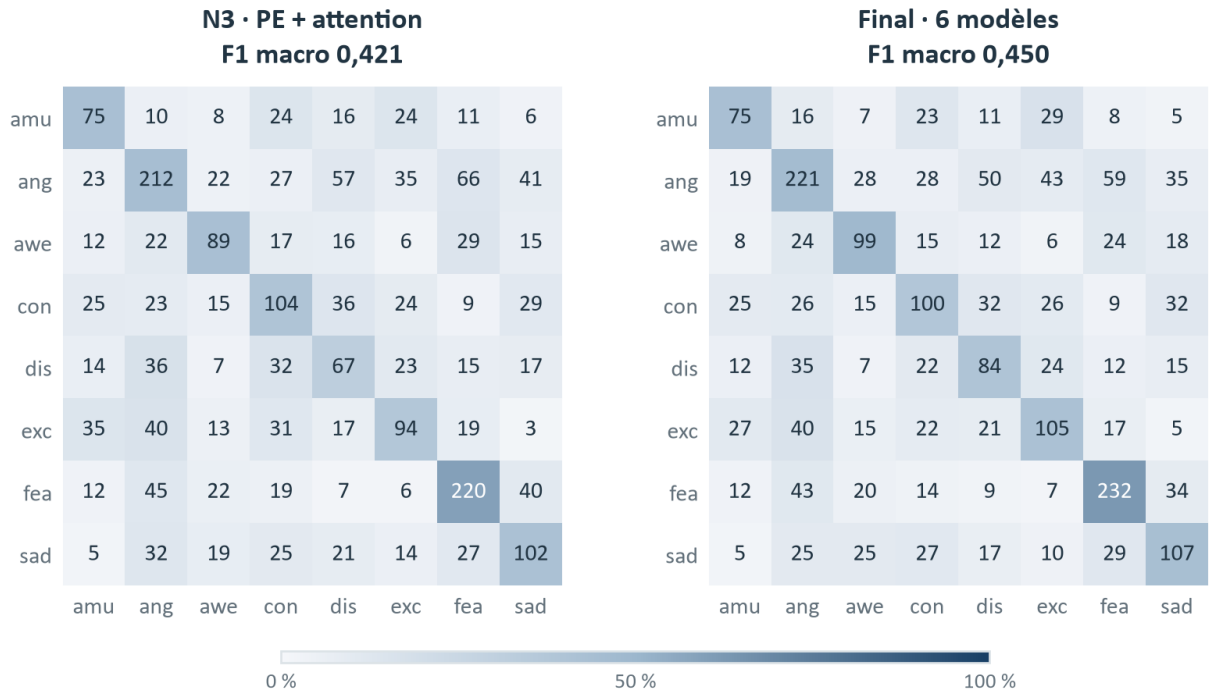


Figure 31 · Validation croisée · N3 et système final. Même échelle de 0 à 100 %.

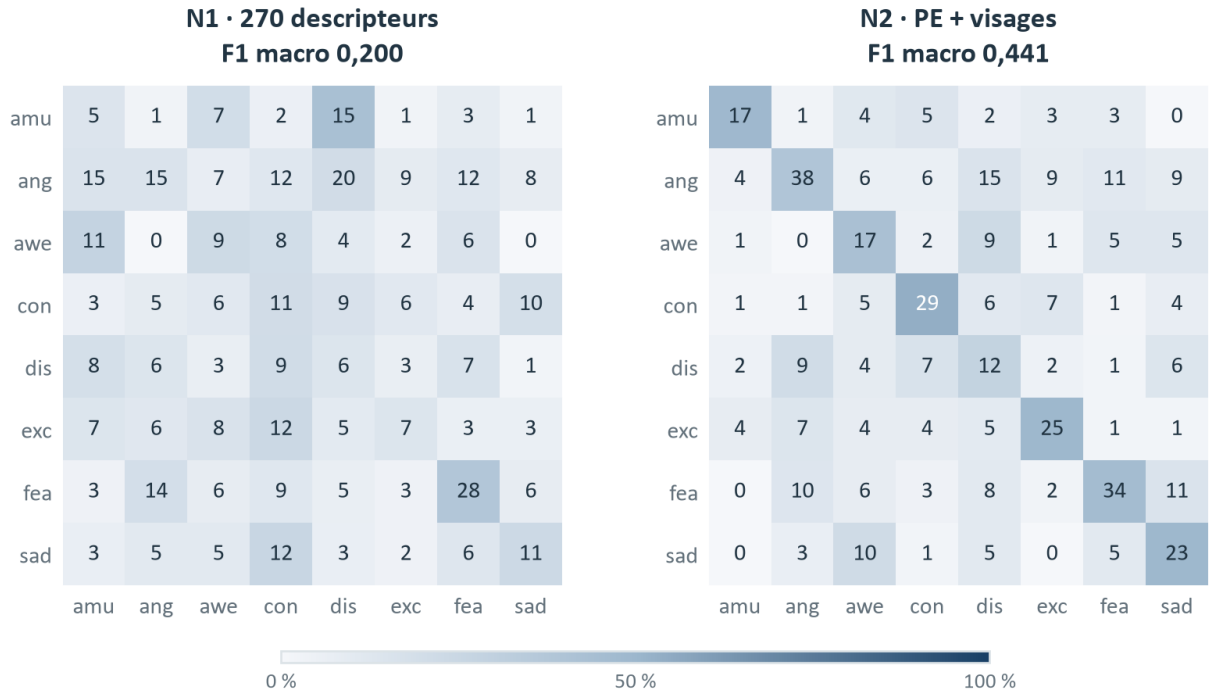


Figure 32 · Développement · N1 et N2. Lignes : émotion réelle ; colonnes : prédiction. Cases : effectifs ; couleur : part par ligne.

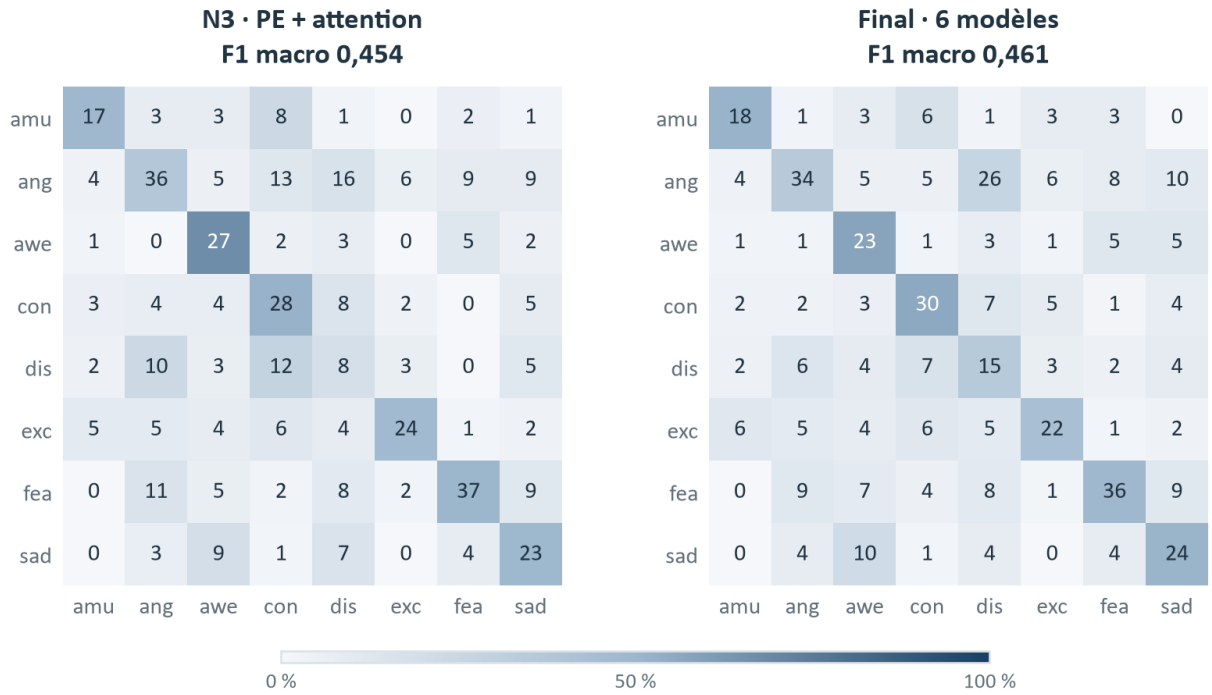


Figure 33 · Développement · N3 et système final. Même échelle de 0 à 100 %.

La vidéo est la meilleure modalité pour presque toutes les émotions. Elle reconnaît bien la **peur**, la **satisfaction** et l'**amusement**, et peine sur le **dégoût**, souvent confondu avec la colère : les deux montrent des visages crispés et des scènes tendues. Le saut entre N1 (couleurs) et N2 (encodeurs) est le plus fort de tout le projet, de 0,19 à 0,43 : comprendre le contenu d'une image compte bien plus que ses couleurs.

> **À RETENIR**
>
> Le contenu des images compte davantage que leur couleur ou leur mouvement. Les visages complètent les encodeurs. La vidéo domine, en cohérence avec une annotation principalement visuelle.

8. Fusion des modalités (point 5)

> **EN BREF**
>
> Trois options sont comparées : moyenne des probabilités, concaténation des vecteurs et attention multimodale. Le choix est arrêté par F1 cv. La moyenne pondérée est retenue avec les poids vidéo 0,6, texte 0,2 et audio 0,2. L'évaluation test est présentée ici.

8.1 Principe et entrées

La fusion part de ce que chaque modalité a produit au point 4 : ses **probabilités** (une par émotion et par extrait) et, pour train, ses **probabilités hors pli**. Ces dernières sont indispensables : elles permettent d'apprendre comment combiner les modalités (poids, classifieur, réseau) sur 2 207 extraits de train, avec des prédictions de modèles qui n'ont pas vu l'extrait, exactement comme le seront celles de dev et de test. Sans elles, il aurait fallu apprendre la fusion sur dev, qui n'aurait plus été une mesure indépendante.

Pour les options B et C, il faut aussi des **vecteurs** : chaque modalité y est représentée par son meilleur encodeur gelé. Les vecteurs vidéo ont été recalculés avec les scripts du module vidéo, sans modification ; ils

redonnent exactement ses scores (PE moyenné, sans visages : 0,4241 en CV, 0,4110 sur dev), ce qui confirme que le module se reproduit sur une autre machine.

8.2 Les trois options

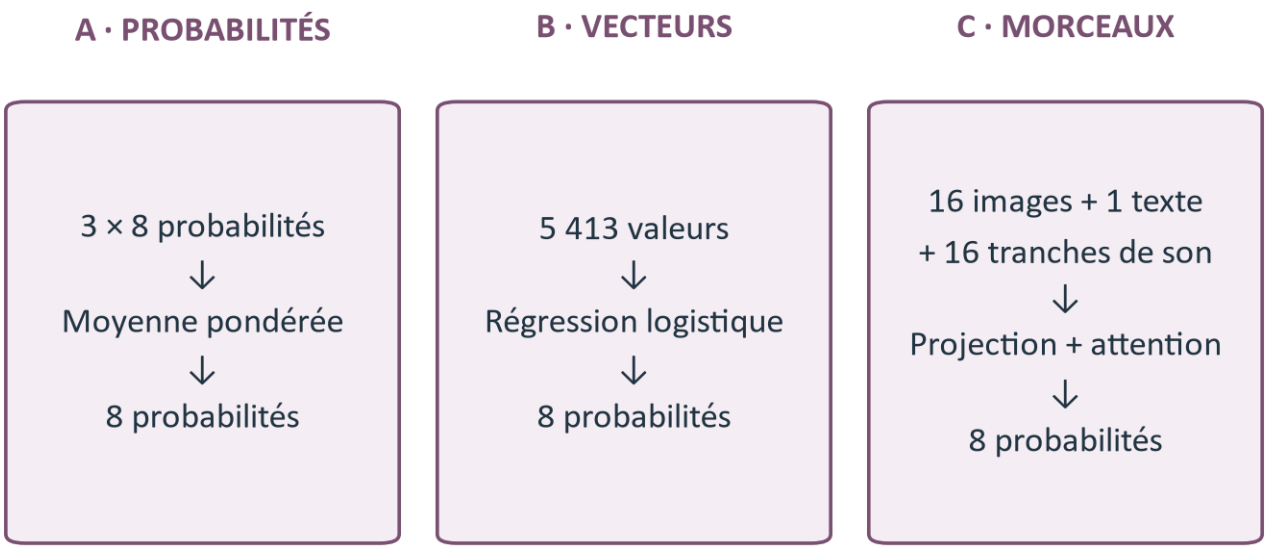


Figure 34 · Les trois façons de fusionner. A combine les probabilités (3 poids appris) ; B met les vecteurs bout à bout (un classifieur) ; C apprend un petit réseau à attention sur les morceaux des trois modalités.

8.3 Option A : fusion tardive

Chaque modalité a déjà « voté » avec ses 8 probabilités ; on combine les votes, comme un jury de trois experts. Trois variantes sont comparées.

- **Moyenne simple** : p = (p_vidéo + p_texte + p_audio) / 3.
- **Moyenne pondérée** : p = (w_v × p_vidéo + w_t × p_texte + w_a × p_audio) / (w_v + w_t + w_a). Chaque poids est essayé de 0 à 1 par pas de 0,1, soit 11 × 11 × 11 − 1 = 1 330 combinaisons ; chacune est évaluée sur les probabilités hors pli de train, et l'on garde la meilleure. Seules les proportions comptent : le réglage trouvé, 0,3 / 0,1 / 0,1, est le même que 3 / 1 / 1 ou que 0,6 / 0,2 / 0,2.
- **Stacking** : une régression logistique reçoit les 24 log-probabilités (3 modalités × 8) et apprend des règles plus fines (par exemple « croire le texte quand il dit *disgust* »). Son réglage C est choisi en validation croisée.

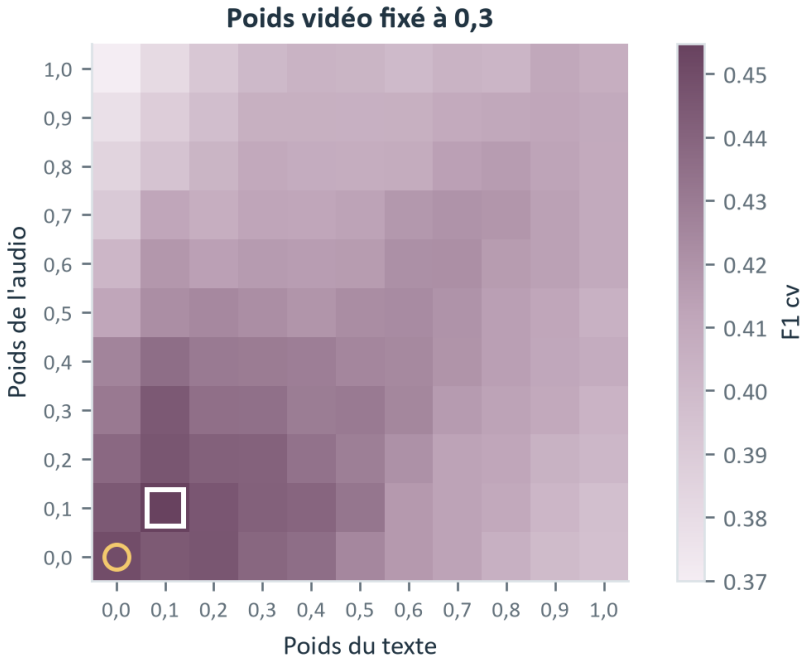


Figure 35 · F1 cv de la moyenne pondérée selon les poids du texte et de l'audio, le poids de la vidéo étant fixé à 0,3. Le carré blanc marque le meilleur réglage (texte 0,1, audio 0,1) ; le cercle jaune, la vidéo seule (poids 0 pour le texte et l'audio).

Tableau 23 · Option A, sur les systèmes finaux du point 4

Méthode	Poids ou réglage	F1 cv	F1 dev
Vidéo seule	—	0,450	0,461
Moyenne simple	1 / 1 / 1	0,435	0,451
Moyenne pondérée	**vidéo 0,6, texte 0,2, audio 0,2**	**0,455**	**0,486**
Stacking	C = 0,003, classes pondérées	0,412	0,452

Tableau 24 · Apport de chaque modalité (moyenne pondérée)

Modalités	Poids retenus	F1 cv	F1 dev
Vidéo + texte	0,7 / 0,1	0,451	0,474
Vidéo + audio	0,1 / 0	0,450	0,461
Texte + audio	0,2 / 0,1	0,371	0,390
Vidéo + texte + audio	0,3 / 0,1 / 0,1	**0,455**	**0,486**

- La **moyenne simple dégrade** la vidéo seule : elle donne autant de poids à l'audio (0,271) et au texte (0,362) qu'à la vidéo (0,450). Il faut des poids.
- Le **stacking** a trop de paramètres (24 × 8 + 8 = 200) pour 2 207 exemples ; il fait moins bien que la moyenne simple en validation croisée.
- **Seul avec la vidéo, l'audio n'apporte rien** (son poids choisi est 0) ; **avec le texte, il reçoit le même poids que lui**, et le trio dépasse la paire vidéo + texte.

8.4 Option B : fusion précoce

On revient un cran en arrière : au lieu de combiner les réponses, on combine les **vecteurs**, avant toute décision. Pour chaque extrait, on met bout à bout :

- **vidéo** : PE moyenné sur les 16 images (1 024 valeurs) et le résumé des visages ViT et HSEmotion (2 084) ;
- **texte** : e5-large sur la description et le dialogue (1 024) et l'indicateur « dialogue présent » (1) ;
- **audio** : Whisper, couche 16, moyenne dans le temps (1 280).

Ces **5 413 valeurs** sont standardisées, puis une seule régression logistique apprend (C et pondération des classes choisis en validation croisée), soit 43 312 paramètres. Deux variantes : **brute** (chaque colonne compte autant, donc la vidéo, avec 3 108 colonnes, pèse le plus) et **équilibrée** (chaque modalité est multipliée par racine(dimension moyenne / sa dimension), pour que les trois aient le même poids total).

Tableau 25 · Option B

Variante	Modalités	F1 cv	F1 dev
Brute	vidéo seule (référence)	0,431	0,441
Brute	vidéo + texte + audio	0,428	0,438
Équilibrée	vidéo + texte + audio	0,415	0,438
Brute	vidéo + texte	0,428	0,469
Brute	vidéo + audio	0,423	0,432

En théorie, cette fusion peut apprendre des combinaisons (une image sombre avec une voix calme n'est pas une image sombre avec des cris). En pratique, **elle ne bat pas la vidéo seule** : avec 2 207 exemples, les colonnes du texte et de l'audio ajoutent surtout du bruit, et un seul réglage C pour toutes les colonnes empêche de donner moins de poids à une modalité sans en donner moins aux autres. Donner le même poids aux trois aggrave le problème.

8.5 Option C : un petit modèle multimodal à attention

L'option C reprend le principe de la tête d'attention du N3 (partie 5.4), mais avec **trois modalités à la fois**. Les trois encodeurs restent gelés ; seul un petit réseau est appris.

Étape 1 — Les trois encodeurs gelés et ce qu'on prend de chacun

Tableau 26 · Les entrées de l'option C (tous des encodeurs gelés, aucun décodeur)

Modalité	Modèle	Ce qu'on lui donne	Ce qu'on récupère par morceau
Vidéo	PE, *Perception Encoder Core L/14-336* (Meta, 2025) : encodeur d'images entraîné sur des paires image-texte	chacune des 16 images	1 024 valeurs (son vecteur final)
Visage (avec la vidéo)	YuNet (détection) + ViT entraîné sur FER2013 (expressions)	le plus grand visage de chaque image	777 valeurs : présence, taille, vecteur de 768, 7 probabilités d'expression (0 si aucun visage)
Texte	e5-large-v2 : encodeur de phrases à 24 couches	la description suivie du dialogue	1 024 valeurs (moyenne de la dernière couche) + 1 « dialogue présent »
Audio	encodeur de Whisper large-v3 (32 couches)	le son, coupé en 16 tranches de même durée	1 280 valeurs par tranche (moyenne de toutes les couches sur la tranche)

Chaque extrait devient ainsi une suite de **33 morceaux** : 16 images (1 801 valeurs chacune), 1 texte (1 025) et 16 tranches de son (1 280). Ce sont les mêmes encodeurs que ceux du point 4 : rien de nouveau n'est entraîné dans ces modèles. Chaque modalité est standardisée avec la moyenne et l'écart-type de ses extraits d'apprentissage.

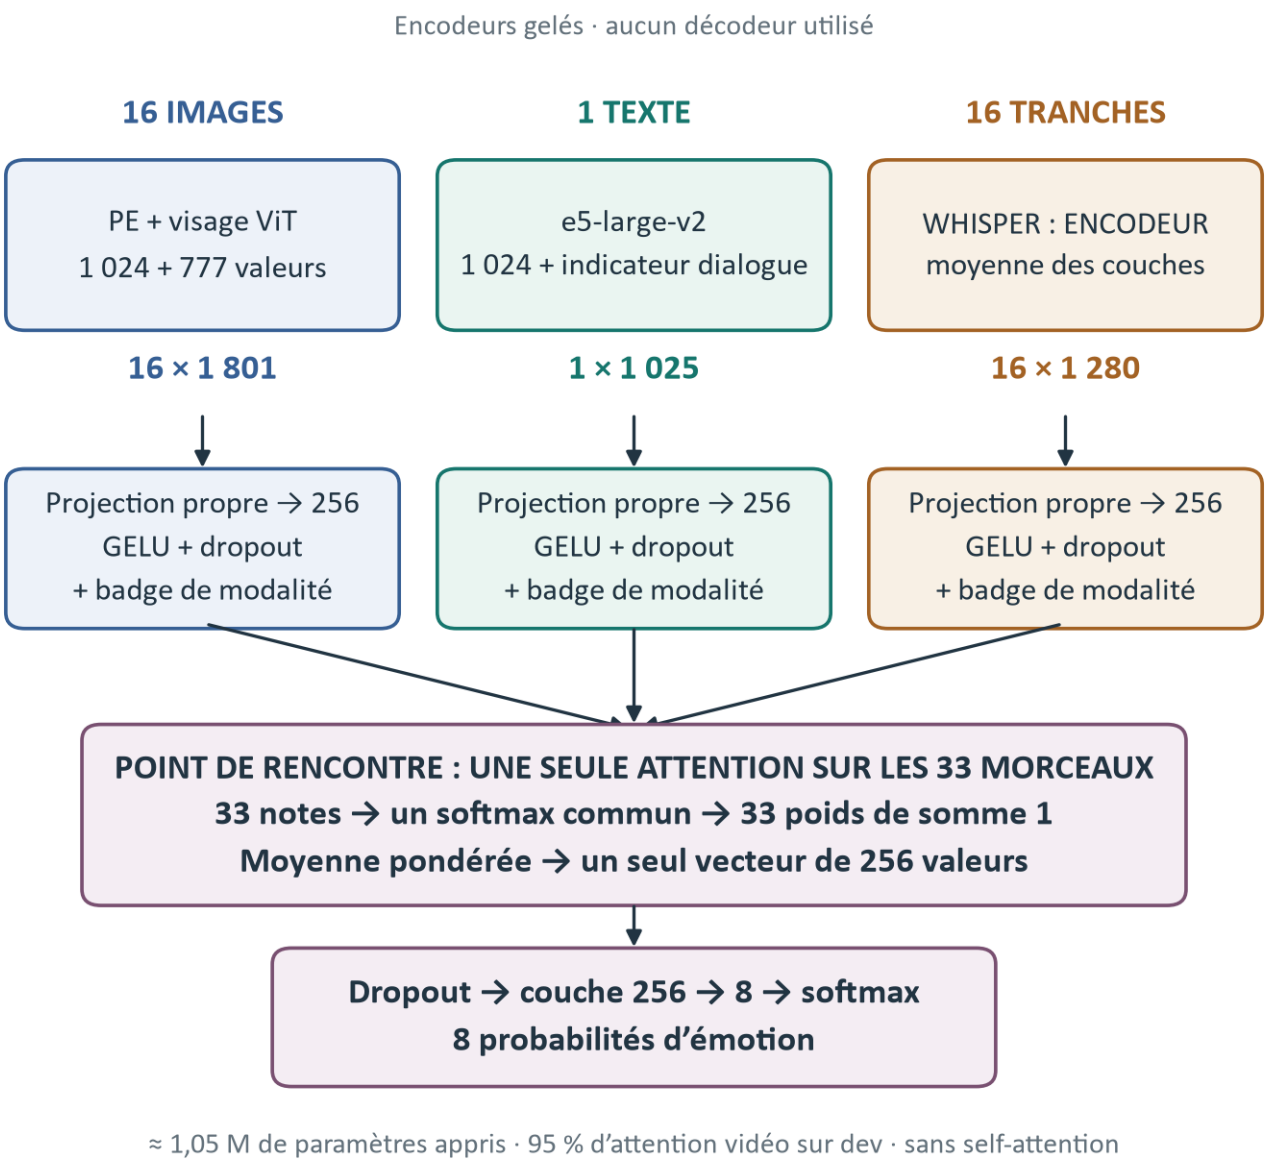


Figure 36 · Architecture de l'option C. Les couleurs identifient la vidéo, le texte et l'audio. Les encodeurs sont gelés ; les projections, badges, notes d'attention et sorties sont appris. Les trois branches se rejoignent dans une unique attention sur les 33 morceaux.

Étape 2 — Mettre les trois modalités à la même taille

Une image, un texte et une tranche de son n'ont ni la même taille ni le même sens : on ne peut pas les comparer directement. Chaque modalité passe donc par **sa propre couche de projection** (linéaire, puis GELU et dropout), qui la ramène à **256 valeurs** : une projection pour les images, une pour le texte, une pour le son. La même projection sert pour les 16 images ; une autre sert pour les 16 tranches.

On ajoute ensuite à chaque morceau un « **badge** » **de modalité** : un vecteur de 256 valeurs, appris, propre à chaque modalité. Il indique au réseau si le morceau vient d'une image, du texte ou du son.

Étape 3 — Le point de rencontre : l'attention

Les 33 vecteurs, désormais de même taille, sont mis dans une seule liste. Un neurone donne une **note d'importance** à chacun ; un *softmax* transforme les 33 notes en 33 poids qui font 100 % ; la **moyenne pondérée** des 33 vecteurs donne **un seul vecteur de 256 valeurs**, qui résume l'extrait entier, toutes modalités confondues. C'est là que les trois branches se rejoignent.

Une option supplémentaire a été testée avant cette étape : une couche de *self-attention* (Transformer, 4 têtes), où chaque morceau peut « regarder » les autres (une image regarde une tranche de son, par exemple). Optuna ne l'a **pas retenue** : elle n'aidait pas avec si peu de données.

Étape 4 — La décision

Le vecteur de 256 valeurs passe par un dropout et une couche de sortie de 8 neurones ; un *softmax* donne les 8 probabilités. En formules, pour un morceau x de la modalité m :

projection : z = dropout(GELU(W_m · x + b_m)) + badge_m (256 valeurs)

note : s = w · z + b (un nombre par morceau)

poids : a = softmax(s) sur les 33 morceaux (33 poids, total 1)

résumé : h = somme des a × z (256 valeurs)

sortie : p = softmax(W_out · dropout(h) + b_out) (8 probabilités)

Apprentissage

- Entropie croisée pondérée par classe, optimiseur AdamW, lots de 64 extraits, nombre d'époques fixé.
- Pour que le réseau n'écoute pas que la vidéo, deux « coups de frein » à chaque lot : une partie des 33 morceaux est cachée au hasard, et **chaque modalité entière peut être cachée indépendamment**, pour chaque extrait (toutes ses images, tout son texte ou tout son son). Au moins un morceau est ensuite conservé. Le réseau doit alors se débrouiller sans elle.
- Réglages choisis par **30 essais Optuna**, chacun évalué en validation croisée par film : taille (128 ou 256), avec ou sans couche de self-attention, dropout (0,1 à 0,6), taux d'apprentissage (1e-4 à 3e-3), régularisation (1e-4 à 0,1), époques (5 à 40), part de morceaux cachés (0 à 50 %), probabilité de cacher une modalité (0 à 40 %).
- **Réglage retenu** : 256, sans self-attention, dropout 0,31, taux d'apprentissage 1,5e-4, régularisation 0,0025, 16 époques, 19 % des morceaux cachés, probabilité de masquage de 19 % par modalité et par extrait.
- Le réglage retenu est réappris avec 3 graines (probabilités moyennées), en validation croisée pour obtenir les probabilités hors pli, puis sur tout train pour prédire dev et test.

Tableau 27 · Taille de l'option C (paramètres appris)

Partie	Calcul	Paramètres
Projection des images	1 801 × 256 + 256	461 312
Projection du son	1 280 × 256 + 256	327 936
Projection du texte	1 025 × 256 + 256	262 656
Badges de modalité	3 × 256	768
Neurone de score	256 + 1	257
Couche de sortie	256 × 8 + 8	2 056
Total		**1 054 985 (≈ 1,05 million)**

Résultats

F1 cv 0,439, F1 dev 0,450. Le modèle fait mieux que la vidéo seule avec les mêmes entrées (0,431) et que la fusion précoce (0,428). Mais sur dev, il donne en moyenne **95 % de son attention aux images**, 3 % au texte et 2 % au son : malgré les modalités cachées pendant l'apprentissage, il a appris que la vidéo suffit presque. C'est cohérent avec l'annotation du corpus, faite à partir des images.

Un grand modèle multimodal pré-entraîné (du type Qwen2.5-Omni, qui traite à la fois images, son et texte) n'a pas été essayé : il ne tient pas sur une carte graphique de 8 Go, et l'affiner avec 2 207 exemples poserait le même problème de données.

8.6 Comparaison et choix du système final

B et C n'utilisent qu'un encodeur par modalité, alors que A profite des systèmes finaux du point 4 (texte affiné, combinaisons de 4 à 6 modèles). Pour comparer à armes égales, A a aussi été appliquée aux mêmes entrées que B et C.

Tableau 28 · Comparaison des trois options

Option	Système	Paramètres appris	F1 cv	F1 dev
A	moyenne pondérée, systèmes finaux du point 4	3 poids	**0,455**	**0,486**
A	moyenne pondérée, mêmes entrées que B et C	3 poids	0,448	0,454
C	attention multimodale	≈ 1 050 000	0,439	0,450
B	concaténation, brute	43 312	0,428	0,438

Même à entrées égales, la fusion tardive reste devant. Plus une méthode apprend de paramètres, plus elle a besoin de données ; avec 2 207 extraits, apprendre trois poids est plus sûr qu'en apprendre un million. **Système retenu : option A, moyenne pondérée (vidéo 0,6, texte 0,2, audio 0,2)**, parce qu'elle a le meilleur F1 cv.

8.7 Résultat final sur test

Tableau 29 · Scores finaux (test calculé une seule fois)

Système	F1 cv	F1 dev	F1 test
Audio seul	0,271	0,270	0,297
Texte seul	0,362	0,387	0,365
Vidéo seule	0,450	0,461	0,413
Fusion (moyenne pondérée)	**0,455**	**0,486**	**0,419**

Tableau 30 · Système retenu, sur dev et sur test

	F1 macro	Exactitude	Gain sur la vidéo seule (IC 95 % par films)
dev	0,486	48,2 %	+0,025 [+0,001 ; +0,053] : significatif
test	0,419	44,4 %	+0,006 [−0,017 ; +0,030] : non significatif

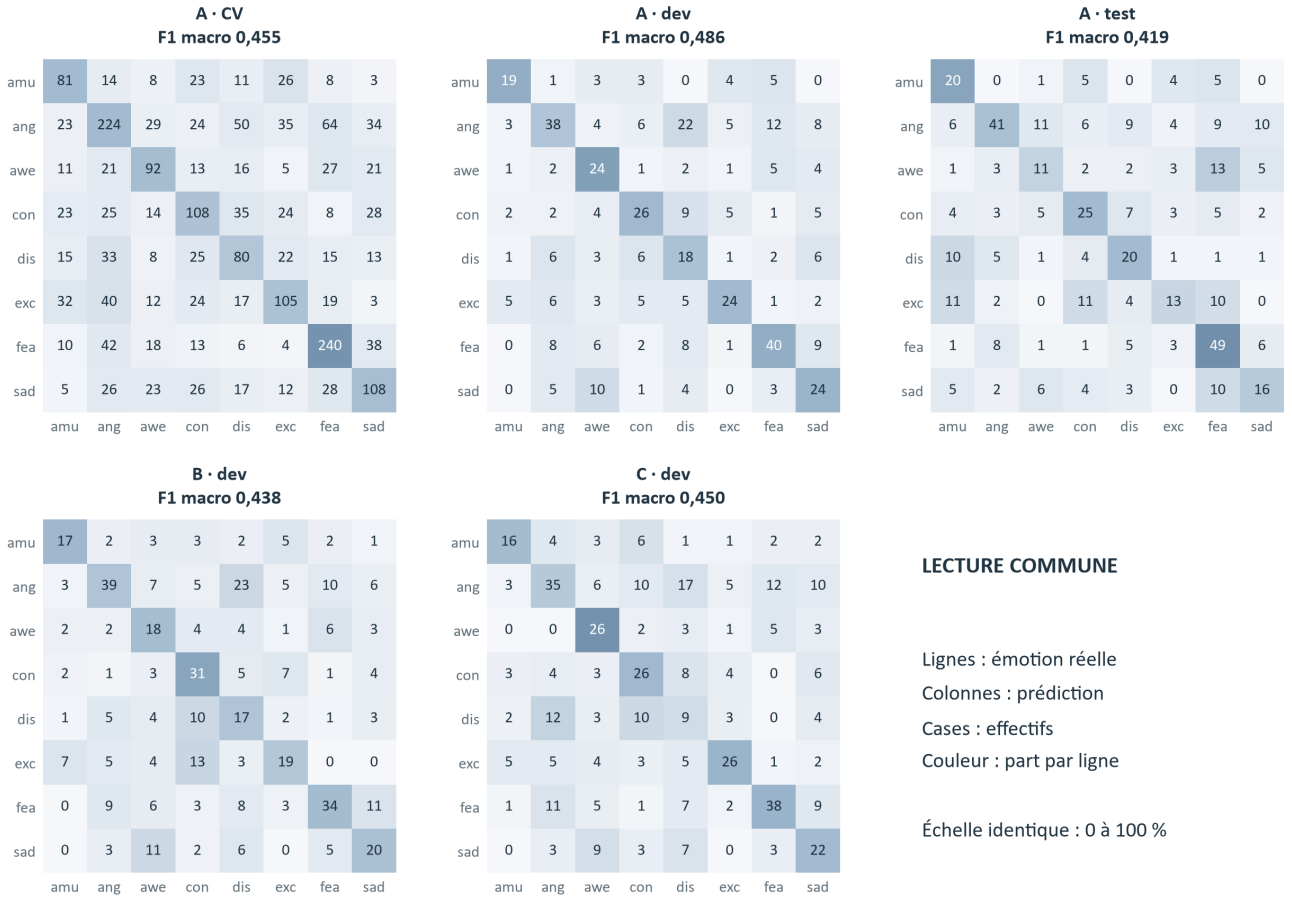


Figure 37 · Matrices de confusion de la fusion : système retenu en validation croisée, sur dev et sur test, puis options B et C sur dev.

- sur test, les trois émotions positives se mélangent : l'excitation est prise pour de l'amusement ou de la satisfaction (11 extraits chacun), et l'émerveillement est souvent pris pour de la peur (13). C'est ce qui explique les rappels faibles d'*awe* (28 %) et d'*excitement* (25 %) sur test.

8.8 Cohérence des mesures

- **CV et dev sont proches** : audio 0,271 / 0,270 ; vidéo 0,450 / 0,461. Dev contrôle la généralisation des réglages choisis sur train.
- **Test est plus difficile que dev pour la vidéo et le texte, mais pas pour l'audio** (tableau final). Avec 50 films par ensemble, quelques films peuvent déplacer les scores de plusieurs points ; les intervalles par films quantifient cette incertitude.
- **La fusion reste la meilleure sur test**, mais son avance sur la vidéo n'y est plus significative.

> **À RETENIR**
>
> L'option A atteint 0,455 en CV, 0,486 sur dev et 0,419 sur test. Le gain sur la vidéo est significatif sur dev, mais pas sur test. L'option C apprend environ 1,05 million de paramètres et attribue 95 % de son attention aux images.

9. Analyse des erreurs

EN BREF

Les modalités ne font pas les mêmes erreurs. La vidéo reconnaît le mieux la plupart des émotions, le texte aide pour le dégoût et l'audio pour la tristesse. Les émotions positives proches restent difficiles à distinguer. L'analyse s'appuie sur dev et les prédictions hors pli.

9.1 Par émotion

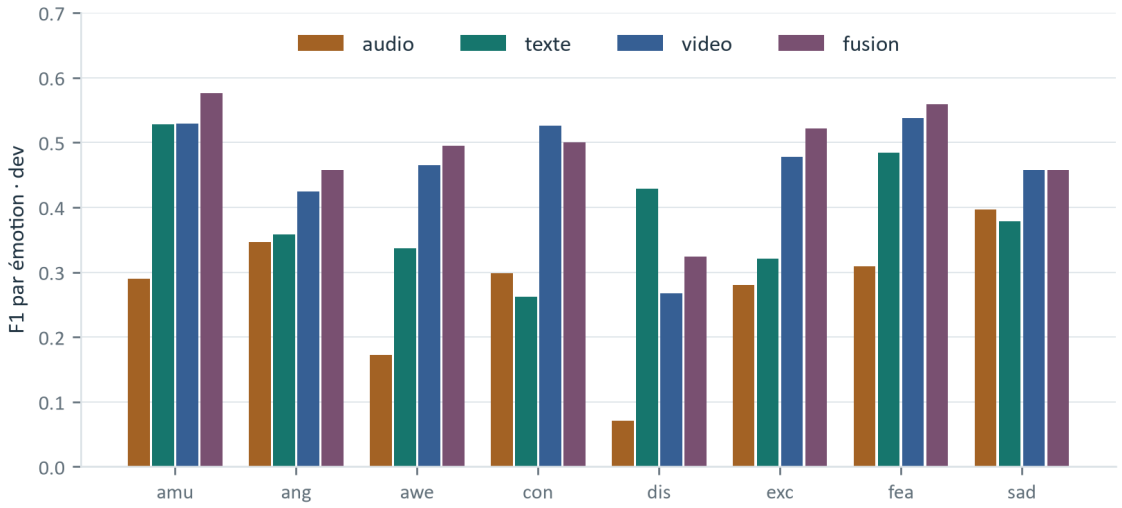


Figure 38 · F1 par émotion sur dev pour chaque modalité et pour la fusion.

Tableau 31 · F1 par émotion (dev)

Émotion	Audio	Texte	Vidéo	Fusion
amusement	0,29	0,53	0,53	**0,58**
anger	0,35	0,36	0,42	**0,46**
awe	0,17	0,34	0,46	**0,49**
contentment	0,30	0,26	**0,53**	0,50
disgust	0,07	**0,43**	0,27	0,32
excitement	0,28	0,32	0,48	**0,52**
fear	0,31	0,48	0,54	**0,56**
sadness	0,40	0,38	**0,46**	**0,46**

- Aux arrondis présentés, la fusion égale ou dépasse la vidéo sur **7 émotions sur 8** (seule exception : *contentment*).
- **Le texte est la meilleure modalité pour le dégoût** (0,43 contre 0,27 pour la vidéo). La fusion, qui donne le même petit poids au texte pour toutes les émotions, n'en récupère qu'une partie (0,32).
- **L'audio a sa meilleure émotion avec la tristesse** (0,40), presque au niveau de la vidéo : la tristesse s'entend dans la voix et la musique. Il est en revanche presque aveugle au dégoût (0,07) et à l'émerveillement (0,17).

9.2 Les erreurs les plus fréquentes

D'après les matrices de confusion de la fusion :

- en validation croisée, la confusion la plus fréquente est **la colère prise pour de la peur** (64 extraits), puis la colère prise pour du dégoût (50) et la peur prise pour de la colère (42) : les émotions « négatives et fortes » se ressemblent, à l'image comme au son ;
- sur dev, la colère est souvent prise pour du dégoût (22 extraits) ;

9.3 Ce que chaque modalité apporte

Tableau 32 · Synthèse des apports

Constat	Explication
La vidéo domine	Annotation faite à partir des images ; encodeurs image-texte très performants
Le texte aide surtout par la description	La description décrit l'image ; le dialogue seul est faible (F1 ≈ 0,17) et absent d'un tiers des extraits
L'audio est faible seul, mais utile en complément	Il porte des indices différents (intensité, timbre, musique), surtout pour la tristesse
Les fusions qui apprennent beaucoup échouent	2 207 extraits d'apprentissage ne suffisent pas pour des milliers de paramètres

> **À RETENIR**
>
> La complémentarité est réelle mais inégale selon l'émotion. Une pondération identique pour toutes les classes ne récupère qu'une partie des apports du texte et du son.

10. Conclusion, limites et pistes

> **EN BREF**
>
> Les encodeurs pré-entraînés réalisent l'essentiel du gain. Les combinaisons exploitent la diversité de leurs erreurs. Une fusion simple reste la plus adaptée aux 2 207 exemples d'apprentissage. Les limites viennent des données, de leur annotation et des petits ensembles d'évaluation.

Conclusion

Nous avons construit, pour chaque modalité, une chaîne allant de descripteurs classiques (N1) à des encodeurs pré-entraînés gelés (N2) et à des modèles partiellement appris (N3), avec un protocole commun : tous les choix par validation croisée groupée par film sur train, dev réservé à la mesure, test utilisé une seule fois. Les encodeurs pré-entraînés font l'essentiel du travail ; l'attention et le fine-tuning apportent surtout de la diversité, utile aux combinaisons. La fusion tardive par moyenne pondérée dépasse la vidéo seule (0,486 contre 0,461 sur dev, gain significatif ; 0,419 sur test), alors que la fusion précoce et le modèle multimodal à attention, plus ambitieux, ne font pas mieux avec si peu de données.

Limites

- **Biais de l'annotation** : 80 % des étiquettes viennent d'un modèle qui ne voit que les images ; nos scores mesurent en partie la capacité à retrouver son jugement, ce qui avantage la vidéo et pénalise l'audio.
- **Peu de données** : 2 207 extraits d'apprentissage limitent tous les modèles qui apprennent beaucoup de paramètres (stacking, fusion précoce, attention, fine-tuning des petits modèles).
- **Petits ensembles d'évaluation** : 50 films en dev comme en test ; des écarts d'un ou deux points ne sont pas significatifs, et test s'est révélé plus difficile que dev.
- **Transcription non évaluée** par un taux d'erreur sur les mots ; cris, rires et pleurs non transcrits.
- **Réglages choisis sur les mêmes prédictions hors pli** : les F1 cv sont légèrement optimistes ; dev et test servent de contrôle.
- **Pas de modèle déployable** : les scripts gardent les vecteurs et les probabilités, pas les poids des classifieurs ; prédire une vidéo extérieure demanderait une chaîne d'inférence dédiée.

Pistes

- Pondérer la fusion **par émotion** (plus de poids au texte pour le dégoût), avec une validation croisée pour éviter le surapprentissage.
- Affiner un encodeur audio de parole (WavLM ou Whisper) au lieu de le garder gelé.
- Mesurer la qualité de la transcription sur un échantillon de dev transcrit à la main.
- Tester un grand modèle multimodal pré-entraîné, gelé, avec plus de mémoire graphique.

> **À RETENIR**
>
> Le système final obtient un F1 macro de 0,419 sur test. Avant de complexifier l'architecture, il faut mieux mesurer la transcription, tester les gains par film et disposer de davantage de données.

Annexe A. Les descripteurs du N1 audio

eGeMAPS v02 (88 valeurs). Les 25 descripteurs de bas niveau, mesurés sur des trames courtes :

Tableau 33 · Descripteurs de bas niveau d'eGeMAPS

Groupe	Descripteurs	Ce qu'ils mesurent
Fréquence	hauteur (F0, en demi-tons), jitter	hauteur de la voix et ses micro-variations
Fréquence	formants F1, F2, F3 : fréquence, largeur de bande, amplitude	résonances du conduit vocal (timbre de la voix)
Énergie	intensité perçue (*loudness*), shimmer, HNR	volume, micro-variations d'intensité, voix claire ou soufflée
Spectre	alpha ratio, indice de Hammarberg, pentes 0–500 Hz et 500–1 500 Hz	répartition de l'énergie entre graves et aigus
Spectre	H1-H2, H1-A3	tension ou relâchement de la voix
Spectre	MFCC 1 à 4, flux spectral	forme du spectre et ses changements

Résumés sur l'extrait : moyenne et coefficient de variation (parties voisées et non voisées séparées pour certains) ; pour la hauteur et l'intensité, centiles 20, 50 et 80, écart entre les centiles 20 et 80, moyenne et écart-type des pentes de montée et de descente. Mesures de rythme : pics d'intensité par seconde, segments voisés par seconde, durée moyenne et écart-type des segments voisés et des pauses, niveau sonore équivalent.

librosa (133 valeurs). Voir le tableau de la partie 5.2 : MFCC (40), dérivées (40), chroma (24), contraste (14), centroïde, largeur de bande, rolloff et platitude (8), énergie, passages par zéro et attaques (6), tempo (1). Les noms exacts des 221 colonnes sont produits par rapport/figures.py.

Annexe B. Les 76 configurations du N2 audio

Tableau 34 · Nombre de configurations par encodeur et par étape

Encodeur	A1 couche	A2 résumé	B ajout	D classifieur	C seul	Total
Whisper	8	1	3	4	—	16
WavLM	8	1	3	4	—	16
wav2vec2 émotion	8	1	3	4	—	16
AST	8	1	3	4	—	16
CLAP	—	2	3	4	—	9
AudioSet seul	—	—	—	—	3	3
Total	32	6	15	20	3	**76**

Couches testées à l'étape A1 : Whisper 0, 5, 11, 16, 21, 27, 32 ; WavLM 0, 4, 8, 12, 16, 20, 24 ; wav2vec2 et AST 0, 2, 4, 6, 8, 10, 12 ; plus la moyenne de toutes les couches. Chaque configuration est évaluée en validation croisée par film, avec sa propre recherche de réglages. Le détail de chaque ligne est dans point4_audio/resultats/scores_n2.csv.

Annexe C. Réglages retenus

Tableau 35 · Réglages retenus en validation croisée pour les principaux modèles

Modèle	Réglage retenu
N1 audio	régression logistique, C = 0,003, classes pondérées
N2 audio Whisper	couche 16, moyenne dans le temps, régression logistique, C = 0,001, classes pondérées
N3 audio Whisper	256 neurones, dropout 0,54, lr 1,2e-4, 31 époques, 20 % des tranches retirées
N3 audio WavLM	256 neurones, dropout 0,57, lr 1,1e-4, 33 époques, 46 % des tranches retirées
Système audio	moyenne de 4 modèles (Whisper et WavLM, N2 et N3)
N1 vidéo	régression logistique, C = 0,0003, classes pondérées
N2 vidéo PE	16 images, moyenne, visages ViT + HSEmotion, régression logistique, C = 0,001, classes pondérées
N3 vidéo PE	visages ViT, 128 neurones, dropout 0,53, lr 3e-4, 17 époques, 26 % des images retirées
Système vidéo	moyenne de 6 modèles
N3 texte ekman	fine-tuning, lr 3e-5, 4 époques, lots de 16
Système texte	moyenne de 6 modèles
Fusion A	moyenne pondérée, vidéo 0,6, texte 0,2, audio 0,2
Fusion B	régression logistique, C = 0,001, classes pondérées
Fusion C	256, sans self-attention, dropout 0,31, lr 1,5e-4, 16 époques, 19 % / 19 %

Annexe D. Organisation du dépôt et reproduction

Tableau 36 · Contenu du dépôt

Dossier	Scripts	Résultats versionnés
point2_partition/	statistiques.py	listes train / dev / test
point3_transcription/	01 à 09 : préparation, transcription, vérification, corpus.csv	transcriptions, décisions, corpus
point4_texte/	01 à 06 : TF-IDF, encodeurs gelés, fine-tuning, combinaisons	scores, probabilités, matrices
point4_video/	00 à 07 : écrans de fin, images, encodeurs, visages, N1, N2, N3, combinaison	idem
point4_audio/	01 à 05 : N1, encodeurs, N2, N3, combinaison	idem
point5_fusion/	01 à 04 : fusion tardive, précoce, attention, comparaison et test	idem
rapport/	dessiner_figures.py, construire_rapport.py, verifier_resultats.py	figures, schémas et contrôles de ce rapport

Le code et les résultats sont publiés sur GitLab : https://gitlab.com/Maouloud3-o/projet-multimedia-m2sid

Le corpus n'est pas versionné : par défaut, les scripts le cherchent dans l'archive du cours décompressée à côté du dépôt (../PROJET_SID_2026/PROJET_SID_2026/movie/), sinon dans la variable EMOVID_DIR (points 2 et 4) ou PROJET_SID_DIR (point 3). Ordre : point 3 (ou directement son corpus.csv), puis les trois modules du point 4 (la vidéo avant l'audio, qui réutilise la détection des écrans de fin), puis le point 5.

Matériel : Python 3.11 et une carte graphique de 8 Go (RTX 5070 Laptop). Durées indicatives : transcription 2 à 3 h, fine-tuning du texte 3 h 30, encodeurs vidéo et audio environ 1 h chacun, fusion moins de 45 min. Depuis ce dépôt, corpus.csv se reconstruit à l'identique, et les combinaisons finales des trois modalités et la fusion redonnent exactement les scores de ce rapport.

Annexe E. Glossaire

Tableau 37 · Glossaire

Terme	Définition
Encodeur	Réseau qui transforme une entrée (son, image, texte) en vecteurs qui la résument
Décodeur	Non utilisé pour les modèles d'émotion des points 4 et 5
Gelé	Modèle dont les poids ne sont pas modifiés ; il ne sert qu'à produire des vecteurs
Couche	Étape d'un réseau ; chaque couche transforme les vecteurs de la précédente
Fine-tuning	Ré-entraînement de toutes les couches d'un modèle pré-entraîné sur nos données
Tête d'attention	Petit réseau qui note l'importance de chaque morceau et en fait une moyenne pondérée
Softmax	Fonction qui transforme des scores en probabilités positives de somme 1
Régularisation (C)	Pénalité sur la taille des poids qui limite le surapprentissage ; petit C = forte pénalité
Validation croisée	Apprentissage sur 4 paquets de films, prédiction du 5e, répété 5 fois
Prédiction hors pli	Prédiction d'un extrait de train par un modèle qui n'a pas vu son film
F1 macro	Moyenne des F1 des 8 émotions, chacune comptant autant
Optuna	Outil qui cherche automatiquement de bons réglages en un nombre d'essais fixé
IC 95 % par films	Intervalle obtenu en rééchantillonnant les films 2 000 fois

Annexe F. Les têtes d'attention couche par couche

Cette annexe détaille, couche par couche, les petits réseaux appris au-dessus des encodeurs gelés : la tête d'attention du N3 vidéo, celle du N3 audio et le modèle multimodal de l'option C. Pour chaque étape, on donne la forme des données qui entrent et qui sortent, et le nombre de paramètres appris. Les dimensions et les réglages sont ceux retenus par Optuna en validation croisée (point4_video/resultats/scores_n3.csv, point4_audio/resultats/scores_n3.csv, point5_fusion/resultats/scores_attention.csv) ; le code est dans point4_video/06_video_n3.py, point4_audio/04_audio_n3.py et point5_fusion/03_fusion_attention.py. Les encodeurs ne sont jamais modifiés et aucun décodeur n'est utilisé.

Les trois réseaux suivent le même principe : (1) chaque morceau (image ou tranche de son) est projeté dans un espace plus petit ; (2) une couche donne une note à chaque morceau ; (3) un softmax transforme les notes en poids dont la somme vaut 1 ; (4) la moyenne pondérée des morceaux donne un seul vecteur ; (5) une dernière couche linéaire sort les 8 émotions. Il s'agit d'une mise en commun par attention, et non d'un Transformer complet : aucun bloc d'auto-attention n'est retenu.

F.1 N3 vidéo : tête d'attention sur 16 images (PE + visage)

Tableau 38 · N3 vidéo, encodeur PE avec les descripteurs de visage (dimension cachée 128)

Étape	Couche	Entrée → sortie	Paramètres appris
0	Encodeurs gelés : PE (1 024) + visage ViT (777) par image, standardisés	16 images → 16 × 1 801	0
1	Linéaire 1 801 → 128, GELU, dropout 0,53 (mêmes poids pour chaque image)	16 × 1 801 → 16 × 128	230 656
2	Linéaire 128 → 1 : une note par image	16 × 128 → 16 notes	129
3	Softmax sur les images présentes (pendant l'apprentissage, 26 % des images retirées au hasard)	16 notes → 16 poids, somme 1	0
4	Moyenne pondérée des 16 vecteurs	16 × 128 → 128	0
5	Dropout 0,53, linéaire 128 → 8, softmax	128 → 8 probabilités	1 032
	Total		**231 817**

La même tête sert aux autres encodeurs d'images ; seule la taille de l'entrée change. Pour SigLIP 2 (1 152 + 777 = 1 929 valeurs par image, dimension cachée 256), elle compte 496 393 paramètres. Le système vidéo final garde les têtes d'attention de PE et de SigLIP 2. Apprentissage : AdamW, lr $3{,}0 \times 10^{-4}$, weight decay 0,05, 17 époques, perte pondérée par classe, lots de 64, moyenne de 3 graines.

F.2 N3 audio : tête d'attention sur 16 tranches de son

Tableau 39 · N3 audio, encodeur de Whisper large-v3 (dimension cachée 256)

Étape	Couche	Entrée → sortie	Paramètres appris
0	Encodeur de Whisper gelé : moyenne des couches sur chacune des 16 tranches de même durée, standardisée	16 tranches → 16 × 1 280	0
1	Linéaire 1 280 → 256, GELU, dropout 0,54 (mêmes poids pour chaque tranche)	16 × 1 280 → 16 × 256	327 936
2	Linéaire 256 → 1 : une note par tranche	16 × 256 → 16 notes	257
3	Softmax (pendant l'apprentissage, 20 % des tranches retirées au hasard)	16 notes → 16 poids, somme 1	0
4	Moyenne pondérée des 16 vecteurs	16 × 256 → 256	0
5	Dropout 0,54, linéaire 256 → 8, softmax	256 → 8 probabilités	2 056
	Total		**330 249**

Pour WavLM (1 024 valeurs par tranche, dimension cachée 256, 46 % des tranches retirées), la même tête compte 264 713 paramètres. Ces deux têtes font partie des 4 modèles du système audio final. Apprentissage de la tête Whisper : AdamW, lr $1{,}2 \times 10^{-4}$, weight decay 0,0097, 31 époques, moyenne de 3 graines.

F.3 Option C : le modèle multimodal à attention

Tableau 40 · Option C, couche par couche (dimension cachée 256)

Étape	Couche	Entrée → sortie	Paramètres appris
0	Encodeurs gelés, standardisés : PE + visage (images), e5 + indicateur de dialogue (texte), encodeur de Whisper (son)	16 × 1 801, 1 × 1 025, 16 × 1 280	0
1a	Projection des images : linéaire 1 801 → 256, GELU, dropout 0,31	16 × 1 801 → 16 × 256	461 312
1b	Projection du texte : linéaire 1 025 → 256, GELU, dropout 0,31	1 × 1 025 → 1 × 256	262 656
1c	Projection du son : linéaire 1 280 → 256, GELU, dropout 0,31	16 × 1 280 → 16 × 256	327 936
2	Ajout d'un vecteur appris par modalité (étiquette « image », « texte » ou « son »)	3 × 256	768
3	Mise en commun : les 33 vecteurs sont placés côte à côte	33 × 256	0
4	Auto-attention (1 bloc Transformer, 4 têtes) : proposée à Optuna, **non retenue**	—	0 (527 104 si retenue)
5	Linéaire 256 → 1 : une note par morceau	33 × 256 → 33 notes	257
6	Un seul softmax sur les 33 notes (morceaux retirés au hasard : 19 % ; modalité entière retirée : 19 %)	33 notes → 33 poids, somme 1	0
7	Moyenne pondérée des 33 vecteurs	33 × 256 → 256	0
8	Dropout 0,31, linéaire 256 → 8, softmax	256 → 8 probabilités	2 056
	Total		**1 054 985**

C'est à l'étape 6 que les trois modalités se rejoignent : le même softmax compare les 16 images, le texte et les 16 tranches de son, et décide de la part de chacune dans le vecteur final. Sur dev, 95 % du poids va aux images, 3 % au texte et 2 % au son. Apprentissage : AdamW, lr $1{,}5 \times 10^{-4}$, weight decay 0,0025, 16 époques.

F.4 N3 texte : fine-tuning complet

Le N3 du texte n'utilise pas de tête d'attention : l'encodeur entier est réentraîné (partie 6). Pour le meilleur modèle (ekman, RoBERTa-large, 24 couches de 1 024 valeurs, environ 355 millions de paramètres), le chemin est le suivant.

Tableau 41 · N3 texte, fine-tuning de RoBERTa-large (ekman)

Étape	Couche	Entrée → sortie	Paramètres appris
0	Description et dialogue, découpés en jetons (256 au plus)	texte → 256 jetons	0
1	Les 24 couches de l'encodeur, **toutes mises à jour**	256 jetons → 256 × 1 024	≈ 355 M
2	Vecteur du premier jeton, qui résume le texte	256 × 1 024 → 1 024	0
3	Nouvelle tête : linéaire 1 024 → 1 024, tanh, dropout	1 024 → 1 024	1 049 600
4	Linéaire 1 024 → 8, softmax	1 024 → 8 probabilités	8 200